Experimentálne porovnanie metód hlbokého učenia pre vizuálnu inšpekciu defektov

Peter Palček

Ústav robotiky a kybernetiky, FEI STU v Bratislave

xpalcek@stuba.sk

Slavomír Kajan

Konzultant z Ústav robotiky a kybernetiky, FEI STU v Bratislave

Abstrakt – Detekcia výrobných defektov predstavuje kľúčové úlohy pri zabezpečení kvality v priemyselnej výrobe. V posledných rokoch sa čoraz viac presadzujú prístupy založené na hlbokom učení, ktoré umožňujú automatizovanú identifikáciu anomálií vo vizuálnych dátach s vysokou presnosťou. Medzi najčastejšie využívané metódy patria konvolučné neurónové siete (CNN), autoenkódery (AE) a prístupy orientované na pixelovú klasifikáciu anomálií, napríklad FCDD (Fully Convolutional Data Description). Táto práca sa zameriava na experimentálne porovnanie uvedených troch prístupov, pričom analyzuje ich výkonnosť, robustnosť a praktickú použiteľnosť v reálnom uplatnení.

1 Úvod

Automatizovaná vizuálna kontrola kvality patrí v súčasnosti k najdynamickejšie sa rozvíjajúcim oblastiam priemyselnej umelej inteligencie. Tlak na zvyšovanie efektivity výroby, znižovanie nákladov a elimináciu ľudskej chyby pri inšpekcii vytvára potrebu spoľahlivých a rýchlych systémov schopných odhaľovať výrobné defekty priamo na výrobnej linke. Odlievanie kovov (angl. casting) predstavuje jedno z najrozšírenejších výrobných odvetví, pričom defekty vznikajúce počas tohto procesu — ako sú napríklad studené spoje, preliačiny, metalurgické vady alebo povrchové trhliny môžu zásadne ohroziť funkčnosť a bezpečnosť finálnych produktov.

Tradičné prístupy k detekcii defektov sú spravidla založené na ručnom návrhu pravidiel a príznakov (features) a na klasických metódach spracovania obrazu. Často krát je to iba sledovanie vybraných príznakov a jednoduchými pravidlami a prahovaním sa rozhoduje, či ide o defekt (anomáliu). Klasické metódy spracovania obrazu ako sú napríklad filtrácia, detekcia hrán, segmentácia a morfologické operácie spolu s klasifikačnými metódami ako sú napríklad SVM (Support Vector Machines) alebo rozhodovacie stromy tvoria tradičný prístup strojového učenia.

Súčasné prístupy k detekcii defektov (anomálií) sú založené najmä na hlbokom učení (deep learning), kde neurónové modely sa učia priamo z veľkého množstva dát bez potreby ručne navrhnutých príznakov. Z neurónových sietí sa najčastejšie používajú konvolučné neurónové siete (CNN), autoenkódery (AE) alebo vizuálne transformery (ViT).

Konvolučné neurónové siete sú založené na učení s učiteľom (angl. supervised leaarning), kde model vyžaduje veľké množstvo anotovaných príkladov pre každú triedu defektov. V praxi vo výrobe je však takýto prístup problematický, pretože výrobcovia produkujú len malé množstvá defektných vzoriek, nedostatočné na trenovanie CNN modelov. Tento problém priamo motivuje použitie metód detekcie anomalií, kde model sa trénuje prevažne na normálnych — bezchybných vzorkách a defekty identifikuje ako odchýlky od prednaučenej normy. Sú to modely ako autoenkóder alebo FCDD model, ktoré využívajú učenie bez učiteľa (angl. unsupervised learning) alebo čiastočne riadené učenie (angl. semi-supervised learning).

Cieľom tejto práce je systematicky porovnať všetky tri prístupy z hľadiska presnosti detekcie , pričom CNN predstavuje strop výkonnosti v učení s učiteľom, autoenkóder rekonštrukčno referenčný spôsob bez dohľadu a FCDD moderný , čiastočne dohliadaný prístup s intuitívnou vysvetliteľnosťou pomocou priamo zakomponovaných tepelných máp na výstupe.

2 Vizuálna inšpekcia defektov

Práca bola vypracovaná s dôrazom na verejné i profesionálnejšie dostupné nástroje ako MATLAB R2025b (revidovanie datasetu a FCDD realizácia) s deep learning toolboxom a v neposlednom rade Python Keras.

2.1 Priemyselný dataset

Na účel výskumu boli použité verejné dostupné data priamo z priemyselného prostredia a to konkrétne Indickej spoločnosti PILOT TECHNOCAST s dlhoročnou praxou v oblasti odlievania. Pri odlievaní sa forma obsahujúca dutú komoru naplní roztaveným kovom, ktorá následne ztvrdne do požadovaného tvaru. Keďže tisíce hotových výrobkov sa vyrábajú práve týmito formami, tak je ideálnou modelovou príležitosťou výskumu.

Obsiahnuté vzorky uvažovaného datasetu obsahujú vrchný záber na povrch obežných kolies čerpadiel. Vyberieme si snímky s rozlíšením 300x300 pixelov , ktoré sú monochromatické v odtieňoch sivej. To umožňuje sieti sa priamo zamerať na štruktúry odliatku miesto farebného rozlíšenia , ktoré častokrát nehrá nejakú významnú rolu pri týchto anomáliach.

Keďže uvažované siete pristupujú implementačne k dátam rôzne, tak je nutné si dodatočne prerozdeliť dataset. Daný dataset bol primárne vytvorený ná účely experimentov s CNN sieťami. Autori zároveň naň uplatnili offline augumentácie.



Obr. 1: Vzorka z kategórie def_front reprezentujúca anomálie a napravo ok_front kvalitné odliatky

Tab. 1: Prerozdelenie vzoriek datasetu pre jednotlivé siete

Set	CNN	FCDD	Autoenkóder
Trénovací ok_front	2587	2587	2587
Kalibračný ok_front	-	288	288
Validačný ok_front	288	-	-
Testovací ok_front	262	262	262
Trénovací def_front	3006	30, resp. 150	-
Kalibračný def_front	-	752	752
Validačný def_front	752	-	-
Testovací def_front	453	453	453

Aby bolo možné zabezpečiť objektívne porovnanie na účely evaluačného porovnania, tak *testovací* set sa kompletne ponechal nedotknutý. Výber vzoriek a jeho balansovanie sme tak ponechali na autorov, pričom sme prihliadli na fakt, že dataset bol oporou viacerých obdobných štúdií.

Významnú rolu najmä zohrala selekcia vzoriek do *validačného* , respektíve *kalibračného setu*, pričom využitie *testovacieho* setu by spôsobilo v procese validovania nevyžiadaný únik dát (angl. data leakage) a nemohli by sme tak zaručiť objektivitu nad špecifickosťou modelu.

Nechali sme sa teda inšpirovať MATLAB dokumentáciou FCDD demo ukážky. Tá využívala v procese ladenia (kalibrovania) prahu klasifikácie rozdelenie *kalibračného* setu na úrovni 10% bezchybných snímok a 20% anomálnych z celkového počtu. V našom prípade sme ich realokovali z *trénovacieho* setu. To bolo zabezpečené pomocou MATLAB permutačnej funkcie randsample, ktorá využíva globálny RNG systém generovania na zabezpečenie náhodnosti, ktorá je tu kritická. Na maximalizovanie náhodnosti generátora sme využili semienko (angl. seed) , ktoré sa odvíja od aktuálneho času spustenia scriptu.

Ďalej v kontexte CNN - keďže ide o učenie s učiteľom - tak sme využili v plnom rozsahu všetky zvyšné ostávajúce defektné vzorky , na rozdiel od autoenkódera. Ten na svoje učenie nepotrebuje učiteľa a teda postačujú mu dáta bez anotácií. V prípade originálnej implementácie FCDD autormi je možné pristupovať k trénovaniu rovnako. Pre tento model sme si však vybrali MATLAB implementáciu, ktorá je limitovaná na učenie sa s čiastočným učiteľom. Z tohto dôvodu sa preto do trénovania vždy náhodne vybralo 1% a 5% defektov.

2.2 Trénovanie neurónových modelov

Trénovanie bolo realizované na výskumnom zariadení Ústavu robotiky a kybernetiky FEI STU, pričom jeho hardvér pozostával z následujúpcich komponentov:

Tab. 2: Zapožičané výskumné zariadenie

Komponent	Model
OS	Ubuntu 24.04.3 LTS
GPU	NVIDIA GeForce RTX 5090 (cuda)
CPU	AMD Ryzen Threadripper PRO 5995WX
Operačná pamäť RAM	128 GB DDR4
Pamäť SSD	1 TB NVme

Všetky trénovania boli teda realizované na zariadení umožňujúce paralelné výpočty (cuda technológia) - rapídne zrýchľuje trénovanie využitím tisícok jadier GPU simultánne. Pre účely tejto práce sa zvolili viaceré hyperparametre.

Tab. 3: Nastavenie hyperparametrov trénovania modelov

Parametre	Voľba
Počet epóch	20
Veľkosť dávky	32 vzoriek
Premiešanie (epocha)	trénovanie aj validácia
Optimalizátor	Adam
Krok učenia	1e-3
Ohyb momentu grad.	0.9
Ohyb štvorca grad.	0.999
Epsilon	1e-7
L2 regularizácia	-

Parametre boli zvolené vzhľadom na veľkosť siete, výpočtového výkonu a široko zaužívaných praktík čo sa týče optimalizátora. Prípadné ďalšie sieťovo špecifické nastavenia ako napríklad stratová funkcia, či implementovanie adaptívneho regulátora kroku učenia sú rozobraté v ich príslušných sekciách. Ak nie je uvedené inak, tak následnosť postupu trénovania, kalibrovania a testovania bola podľa konvencií.

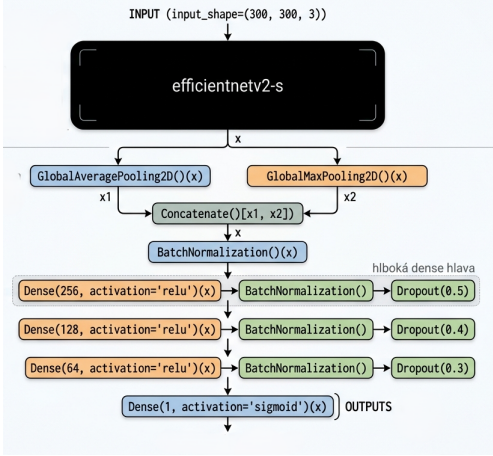
V rámci procesu bola implementovaná aj funkcia zabraňujúca pretrénovaniu, respektíve k podozreniu k jeho nábehu. Tento prípad nenastal vzhľadom na počet epoch, ktorý bol zvolený s dôrazom na jeho intuitívnu minimalizáciu výskytu, najmä pre transferové učenie.

2.3 Konvolučná neurónová sieť (CNN)

Základom vybranej siete (angl. backbone) bola *EfficientNetV2-S* s počtom parametrov 21,4 milióna. *S* verzia využíva technológiu Fused-MBConv (kombinácia 3×3 konvolúcií a 1×1 expanzií), ktorá je optimalizovaná na rýchlosť trénovania a efektívnosť parametrov. Bola vybratá na základe počtu parametrov, ktorý predstavuje jeden z našich výkonnostno-kvalitatívnych ukazovateľov na objektívne porovnanie sietí. V úvahu sa zároveň brala výkonnosť v benchmarkoch na ImageNet1k v porovnaní s podobne veľkými backbones.

V našich experimentoch sme použili prístup transferového učenia, to znamená že sa hlava siete kompletne nahradila za menšiu a zvolil sa 2 fázový prístup tréningu, kedy sa po 8 epochách trénovania novej hlavy siete rozmrazili na doľadovanie (angl. fine tunning) vrchné vrstvy backbone architektúry zodpovedné za extrakciu detailnejších príznakov. Naša sieť tak v konečnom dôsledku pozostávala z 21,040,000 parametrov v produkčnej/výskumnej fáze.

Zároveň bolo nutné predspracovanie dát , keďže vzorky sú v rozsahu pixelov 0-255 a sieť vyžaduje normalizáciu na -1 až 1, respektíve 0 až 1. Tá sa realizuje podľa priemerov a smerodajných odchýlok ImageNet-1K. Sieť natívne pracuje na 384x384 pixelov, takže jednotlivé vstupné vzorky sú v našom prípade centrované na stred horizontálne a vertikálne. Zároveň sú zväčšené bilineárnou interpoláciou - nové pixely vznikajú ako vážený priemer okolitých pixelov.



Obr. 2: Kompletná architektúra CNN siete v Kerase

Kombinovaný Pooling (zhlukovanie): Použitie GlobalAveragePooling2D aj GlobalMaxPooling2D naraz - kým Average pooling zachytáva celkový kontext objektu, Max pooling sa zameriava na najvýraznejšie črty (hrany, textúry). Ich spojením (Concatenate vrstva) sa dáva sieti komplexnejšia informácia.

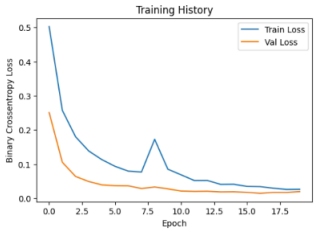
Batch Normalization: Tieto vrstvy stabilizujú učenie tým, že normalizujú aktivácie predchádzajúcich vrstiev. Pomáha to predchádzať problémom s gradientmi a umožňuje nastaviť vyšší krok učenia.

Dropout (0.5 až 0.3): Keďže máme hlbokú plne prepojenú Dense hlavu na zmrazenom modeli, hrozí rýchle preučenie (angl. overfitting). Postupné znižovanie Dropoutu je voleno logicky – najprv silno sa regulú široké vrstvy (256 neurónov) a postupne sa uvoľňuje tlak pri vrstvách s nižším počtom neuŕonov.

V našom prípade budeme trénovať na spôsob binárnej klasifikácie, teda použijeme binárnu krížovú entropiu (1) na hodnotenie procesu trénovania spolu so sigmoid aktivačnou funkciou na výstupe.

$$L = -\frac{1}{N}\sum_{i=1}^{N}[y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)] \qquad (1)$$

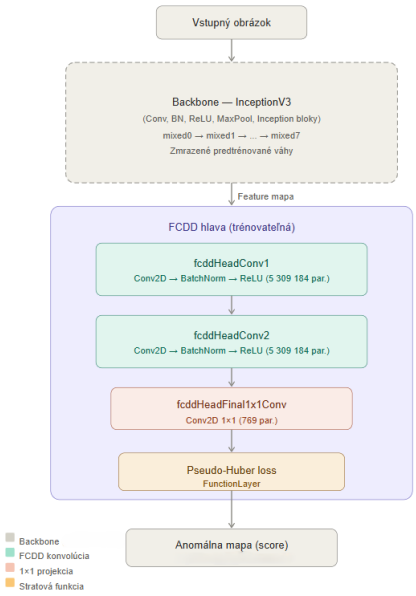
kde $y_i \in \{0, 1\}$ je skutočná trieda, $\hat{y}_i \in (0, 1)$ predpovedaná pravdepodobnosť triedy 1 (sigmoid výstup) a N je veľkosť dávky.



Obr. 3: Priebeh trénovania pre binárnu krížovú entropiu po 20 epochách

Krok učenia bol v druhej fáze (skok na trénovacom priebehu chyby) zmenšený o rád - sieť už len ladila svoje váhy.

2.4 Plne konvolučná dáta popisujúca sieť (FCDD)



Obr. 4: Kompletná architektúra FCDD siete v Matlabe

Opäť základom našej siete je predtrénovaný model a to architektúry Inception-v3. Pôvodný model pozostáva z 23,9

milióna parametrov. Je priamo prispôsobený na extrakciu príznakov z obrázkov rozlíšenia 299x299. Normalizáciu vykonáva samostatne interne a mení rozsah hodnôt vstupných obrázkov na symetrický interval okolo nuly. Aby sme dodržali veľkosťou rozsah siete v okoli 20 miliónov parametrov, tak nevyužijeme celú pôvodnú architektúru, ale 4 z 5 pôvodných úrovní operácie zníženia rozlíšenia (angl. downsampling) enkóderom. MATLAB implementácia je pomerne vysokoúrovňová a teda samotný finalizačný zásah vytvorenia hlavy siete detektora vykoná funkcia fcddAnomalyDetector - podľa veľkosti backbone. Po tomto zásahu je počet parametrov 19,5 milióna.

Backbone (Inception-v3) extrahuje príznaky. Hlava FCDD siete ich premietne cez dve konvolučné vrstvy na kompaktný príznakový priestor a finálna 1×1 konvolúcia zredukuje každý priestorový bod na skalárne skóre. Výsledná mapa - každý pixel hovorí, nakoľko sa daná oblasť obrázka odchyľuje od normálu. Ide o jednu z metód s priamo implementovanou vysvetliteľnosťou siete v podobe tepelných máp.

$$\mathcal{L}_{\text{FCDD}} = \frac{1}{N \cdot |\mathcal{P}|} \sum_{i=1}^{N} \sum_{p \in \mathcal{P}} \left(\sqrt{\left\| \phi(x_i)_p - c \right\|^2 + 1} - 1 \right) \qquad (2)$$

kde:

- N – počet trénovacích vzoriek
- $|\mathcal{P}|$ – počet priestorových pozícií výstupnej mapy
- $\phi(x_i)_p$ – výstup siete v priestorovej pozícii p pre vzorku x_i
- c – centrum hypersféry
- $\| \cdot \|$ – euklidovská norma
- $\sqrt{\cdot + 1} - 1$ – Pseudo-Huber funkcia

FCDD snaží sa namapovať všetky normálne vzorky čo najbližšie k jedinému bodu v príznakopvom priestore — hypersférickému centru c. Tento princíp sa prenáša na priestorovo plne konvolučnú architektúru, takže výstupom nie je jediné skóre pre celý obrázok, ale mapa anomálií s priestorovou lokalizáciou

Obvykle problémom pri anomáliach je, že kvadratická funkcia silno (ako MSE (3)) penalizuje vzdialené body, čo môže spôsobiť kolaps - sieť sa naučí triviálne mapovanie (konštantné príznaky), aby minimalizovala stratu.

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^{N} (\hat{y}_i - y_i)^2 \qquad (3)$$

- $\hat{y}_i$ = **predikovaná hodnota**
- y_i = **cieľová hodnota**
- $\hat{y}_i - y_i$ = **chyba predikcie** pre konkrétny pixel
- N = **počet pixelov** v anomaly score mape

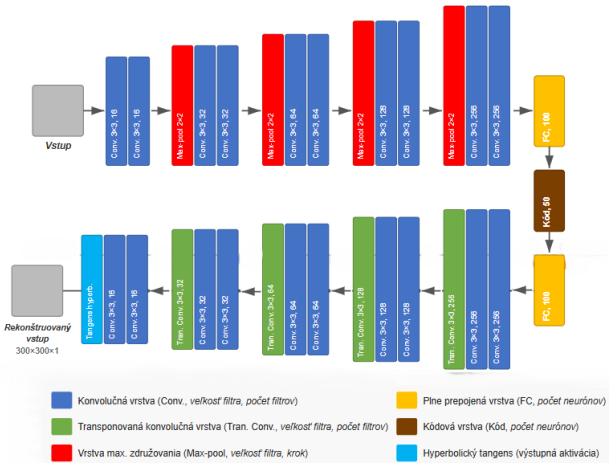
Pseudo-Huber $\sqrt{z^2 + 1} - 1$ rastie lineárne pre veľké z, čím kolaps potláča, a zároveň je hladká v nule (na rozdiel od klasického *MAE*), čo zlepšuje stabilitu gradientov počas tréningu.

Trénovanie bolo realizované aj s podporou anomálnych vzoriek (1% symbol učenia takmer bez učiteľa a 5 %), pričom sme ich zvyšovaním prítomnosti v tréningu demonštrovali ich výrazný vplyv na výkonnosť modelu.

2.5 Autoenkóder

Autoenkodér je typ neurónovej siete s učením bez učiteľa (unsupervised learning), ktorej cieľom je naučiť sa kompaktné vnútorné vyjadrenie vstupných dát — tzv. latentný priestor — a následne z tohto vyjadrenia zrekonštruovať pôvodný vstup. Ide o architektúru tvaru kvázi presýpacích hodín: sieť najprv vstup komprimuje (enkodér) a potom ho opäť rozbalí (dekodér). Keďže sme tvorili sieť z nuly, tak mohli sme určiť jej hĺbku a ovplyvniť počet parametrov, ktorý sa pohyboval na úrovni 22,3 milióna.

Sieť je trénovaná minimalizáciou rekonštrukčnej chyby, typicky strednej kvadratickej odchýlky - MSE aj v našej práci (3). Pretože latentný priestor je výrazne menší ako vstupný priestor, sieť je nútená naučiť sa iba tie vlastnosti dát, ktoré sú významnejšieho charakteru — potláča šum a zachováva štrukturálnu informáciu.

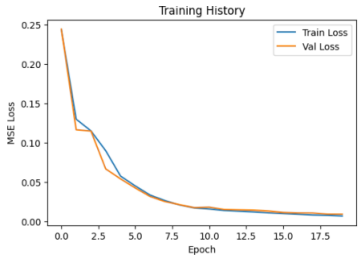


Obr. 5: Kompletná architektúra autoenkódera siete v Kerase

Enkodér sa skladá z piatich postupne sa zužujúcich blokov. Každý blok (okrem posledného) obsahuje dve konvolučné vrstvy nasledované vrstvou MaxPooling2D, ktorá zmenší priestorové rozmery na polovicu. Počet filtrov sa zdvojnásobuje s každým blokom, čím sieť zachytáva stále abstraktnejšie príznaky.

Pred vstupom do latentného priestoru s 50 neurónmi je konvolučný tensor najprv rozvinutý na jednorozmerný vektor hodnôt, a potom postupne komprimovaný cez plne prepojené vrstvy. Latentný priestor predstavuje komprimovanú reprezentáciu celého 300×300 obrazu. Kompresia je extrémna — z 90 000 vstupných pixelov na 50 čísel (pre zujímavosť kompresný pomer 1,800 : 1). Sieť je tak prinútená zakódovať iba podstatné vizuálne informácie a ignorovať šum alebo náhodné odchýlky.

Dekodér je symetrický voči enkodéru. Päť blokov postupne zväčšuje priestorové rozmery pomocou transponovaných konvolúcií späť na pôvodné rozlíšenie.Posledný blok dekodéra obsahuje konvolúciu s 1 filtrom a aktiváciou tanh, ktorá normalizuje výstupné hodnoty do rozsahu -1 až 1. Úplne na výstupe vrstva odreže 2 pixely z každej strany, čím kompenzuje umelé pixely na okrajoch vzniknuté transponovanými konvolúciami a vracia presné pôvodné rozmery 300×300 pixelov. Celý proces sa v technickej terminológií uvádza aj ako generatívna kompresia.



Obr. 6: Priebeh trénovania pre MSE chybu po 20 epochách

2.6 Kalibrovanie

Natrénovaná sieť s nízkymi hodnotami stratových funkcií však ešte nezaručuje kvalitný detektor defektov. Významnou súčasťou návrhu je takzvaná kalibrácia, respektíve úprava prahu klasifikácie. To v praxi znamená, že sa vezme kalibračný set dát a vyhodnotí sa chyba modelu na normálnych a anomálnych dátach — anomálne vzorky majú výrazne vyššiu rekonštrukčnú chybu. V najlepšom prípade je distribúcia chýb tak ideálna, že sa prah dá určiť priamo z histogramu. Podobným spôsobom sme postupovali aj my, no v reálnej praxi nič nebýva ideálne.

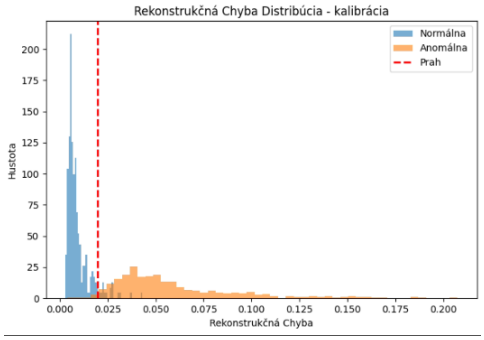
V praxi sa distribúcie skóre normálnych a anomálnych vzoriek čiastočne prekrývajú. Oblasť prekrytia zodpovedá vzorkám, ktoré model nesprávne klasifikuje — buď falošne pozitívnym (FP — normálna vzorka označená ako defekt), alebo falošne negatívnym (FN — defektná vzorka prehliadnutá modelom).

Znižovanie prahu zvyšuje citlivosť (angl. recall), avšak na úkor presnosti (angl. precision): model začne označovať aj niektoré normálne vzorky ako defektné. Tomuto kompromisu sa hovorí precision–recall trade-off. Optimálna voľba závisí od konkrétnej aplikácie a tolerancie voči obom typom chýb.

V kontexte detekcie priemyselných defektov je zvyčajne kritickejšia práve vysoká citlivosť — každý skutočný defekt musí byť zachytený, pretože jeho prehliadnutie má oveľa závažnejšie dôsledky ako falošný alarm. Preto sme pri kalibrácii oboch modelov uprednostňovali maximalizáciu recallu pri súčasnom udržaní primeranej miery falošných alarmov.

Pre oba modely — autoenkodér aj FCDD — sme postupovali nasledovne:

- **Vizualizácia distribúcií skóre:** Vykreslili sme distribúcie rekonštrukčnej chyby (autoenkodér) a agregovaného skóre heatmapy (FCDD) pre normálne aj anomálne vzorky kalibračnej sady a identifikovali oblasť najmenšieho prekrytia ako počiatočný odhad prahu.



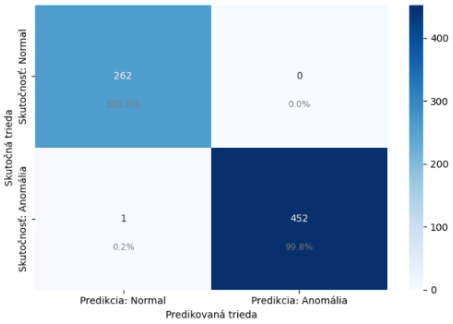
Obr. 7: Ukážka histogramu autoenkódera pri kalibrácií so zvoleným prahom na úroveň 94%

- **Systematické znižovanie prahu:** Prah θ sme iteratívne znižovali tak, aby citlivosť (recall) dosahovala akceptovateľnú úroveň — t. j. aby model neprehliadal skutočné defekty.
- **Monitorovanie presnosti:** Zároveň sme sledovali presnosť, aby počet falošných alarmov zostal v prijateľných medziach pre danú aplikáciu.

Výsledkom je nastavenie, pri ktorom oba modely dosahujú vysokú citlivosť na reálne defekty pri súčasnom udržaní primeranej miery falošných alarmov, čo ich robí prakticky použiteľnými v nasadenom kontrolnom systéme. Finálne nastavený prah bol overený na testovacej sade, ktorú model počas kalibrácie nevidel, čím sa predišlo preoptimalizovaniu (angl. overfitting) na kalibračné dáta

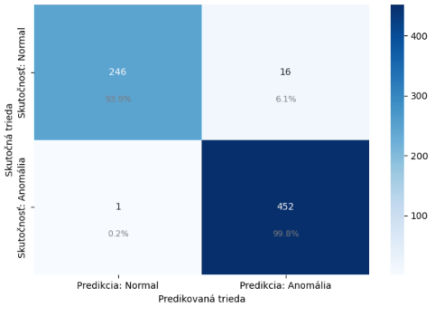
2.7 Vyhodnotenie

Ako prvé sme intuitívne trénovali práve CNN, ktorá je najjednoduchším prístupom čo sa týka nastavení požiadavok na klasifikáciu. Pri nej sa volí prah istoty (angl. confidence threshold) – čo je hraničná hodnota pravdepodobnosti, nad ktorou klasifikátor považuje predikciu za dôveryhodnú. Zvolili sme úroveň 55%, pričom sieť dosahovala počas evaluácie na testovacom sete :



Obr. 8: Kontingenčná matica CNN siete po naladení

Sieť dosahuje perfektné výsledky na nevidených dátach, pričom dosahuje len 1 falošné klasifikovanie anomálie ako bezchybné. Sieť dosiahla obdobné výsledky ako autoenkóder po kalibrácií. Autoenkóder si však vedie v horšie v počte falošných alarmov o celých 16 vzoriek.



Obr. 9: Kontingenčná matica autoenkódera po kalibrácií prahu na úroveň 94%

Pre demonštráciu vplyvu anomálií na trénovanie sa pre FCDD realizovala s 2 rôzne percentuálne veľkými mini setmi počas trénovania:

Tab. 4: Vplyv percentuálneho zakomponovania anomálií na výsledky detektora po zvolení prahu kalibrácie 99%

-	*1%*	*5%*
Citlivosť [Recall]	0.9845	0.9956
Presnosť [Precision]	0.9933	0.9956
f1 skóre	0.9889	0.9956
falošne pozitívne	3	2
falošné negatívne	7	2

Tab. 5: Stručný prehľad TOP dosiahnutých výsledkov

-	*CNN*	*FCDD*	*AE*
Priemerný čas trénovania [min.]	220	145	328
Počet parametrov siete [milióny]	21.04	19.60	22.30
Citlivosť [Recall]	0.9978	0	0.9978
Presnosť [Precision]	1.0000	0	0.9658
f1 skóre	0.9988	0	0.9815

3 Záver

Tento príspevok sa zameral na experimentálne porovnanie troch prístupov hlbokého učenia pre detekciu výrobných defektov: konvolučnej neurónovej siete (CNN), autoenkódera (AE) a metódy FCDD. Výsledky zhrnuté v tabuľke 5 poukazujú na výrazné rozdiely medzi jednotlivými prístupmi z hľadiska presnosti, citlivosti aj výpočtovej náročnosti.

CNN ako supervízovaný prístup dosiahla najvyššiu klasifikačnú presnosť s hodnotou f1 skóre 0,9988, čím potvrdzuje svoju dominantnú pozíciu v úlohách vizuálnej klasifikácie defektov. Zároveň vykazuje nulovú mieru falošne pozitívnych detekcií, čo je z pohľadu priemyselného nasadenia mimoriadne žiaduce. Jej hlavnou nevýhodou zostáva závislosť od dostatočného množstva anotovaných trénovacích dát.

Autoenkóder preukázal konkurencieschopné výsledky s hodnotou f1 skóre 0,9815, pričom dosahuje rovnakú citlivosť ako CNN (0,9978). Jeho nevýhodou je nižšia presnosť (0,9658) v dôsledku vyššieho počtu falošne pozitívnych detekcií, ako aj najdlhší priemerný čas trénovania spomedzi porovnávaných modelov (328 minút).

Metóda FCDD v základnej konfigurácii nedosiahla použiteľné výsledky, avšak experimenty s rôznym percentuálnym zastúpením anomálií v trénovacej množine (tabuľka 4) ukázali, že pri 5 % podiele anomálií metóda dosahuje f1 skóre 0,9956 s len dvoma falošne negatívnymi a dvoma falošne pozitívnymi detekciami. Môžeme teda skonštatovať, že skutočne 5 násobné pridanie anomálií výrazne posilnilo schopnosť siete potlačiť falošne negatívne vzorky. Jej praktickou prednosťou je priestorová interpretovateľnosť prostredníctvom tepelných máp, ktorá uľahčuje diagnostiku a lokalizáciu defektov.

Na základe vykonaných experimentov možno konštatovať, že výber vhodného prístupu závisí predovšetkým od dostupnosti anotovaných dát a požiadaviek konkrétnej aplikácie. V scenároch s dostatočným množstvom označených vzoriek je najvhodnejšie nasadiť supervízovaný model CNN. Naopak, v podmienkach s obmedzeným výskytom defektov alebo pri požiadavke na vizuálnu interpretovateľnosť výsledkov predstavujú autoenkóder a metóda FCDD perspektívne a prakticky využiteľné alternatívy

Poďakovanie

Mile rád by som sa poďakoval pánu doktorovi Slavomírovi Kajanovi z ústavu robotiky a kybernetiky fakulty FEI STU za inšpiráciu i dlhodobé vedenie v oblasti strojového videnia , bez ktorého by táto vedecká iniciatíva pravdepodobne nevznikla. V neposlednom rade by som rád vyzdvihol konštruktívnu kritiku spojenú s nápomocnou relevantnou spätnou väzbou, ktorá umožnila našej spolupráci nabrať reálnu podobu.

Literatúra

[1] J.K. Chow, Z. Su, J. Wu, P.S. Tan, X. Mao, Y.H. Wang. Anomaly detection of defects on concrete structures with the convolutional autoencoder. *ScienceDirect - Advanced Engineering Informatics*, Volume 45:4–5 str., August 2020.

[2] MathWorks. Detect image anomalies using explainable FCDD network. *MATLAB & Simulink Documentation*.

[3] P. Liznerski, L. Ruff, R. A. Vandermeulen, B. J. Franks, M. Kloft, and K.-R. Müller. Explainable deep one-class classification. *Preprint arXiv:2007.01760*, Marec 18, 2021. [Online] `https://arxiv.org/abs/2007.01760`.

[4] L. Ruff, R. A. Vandermeulen, B. J. Franks, K.-R. Müller, and M. Kloft. Rethinking assumptions in deep anomaly detection. *Preprint arXiv:2006.00339*, Máj 30, 2020. [Online] `https://arxiv.org/abs/2006.00339`.

[5] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. *Preprint arXiv:1409.1556*, April 10, 2015. [Online] `https://arxiv.org/abs/1409.1556`.

[6] M. Tan and Q. V. Le. EfficientNetV2: Smaller models and faster training. In *Proc. 38th Int. Conf. Machine Learning (ICML)*, 2021, pp. 10096–10106.

[7] R. Ravirajsinh. Real-life industrial dataset of casting product. Kaggle, 2018. [Online] `https://www.kaggle.com/`.