

Vizuálna kontrola zvarov pomocou hlbokých neurónových sietí

Autor : Bc. Peter Palček

Vedúci DP: Ing. Slavomír Kajan, PhD.

Stručný obsah

- Spracovanie vstupných dát
- CNN klasifikácia
- Implementácia
- Potenciálne vylepšenia a zvýšenie robustnosti







Ciele práce

1. **Naštudujte** metódy klasifikácie zvarov s využitím **HNS.**

2. Oboznámte sa s **existujúcim stavom** riešenia tejto témy a **doplňte dátové sady** na trénovanie a testovanie HNS.

3. Realizujte **prepojenie** kamerových a laserových dát.

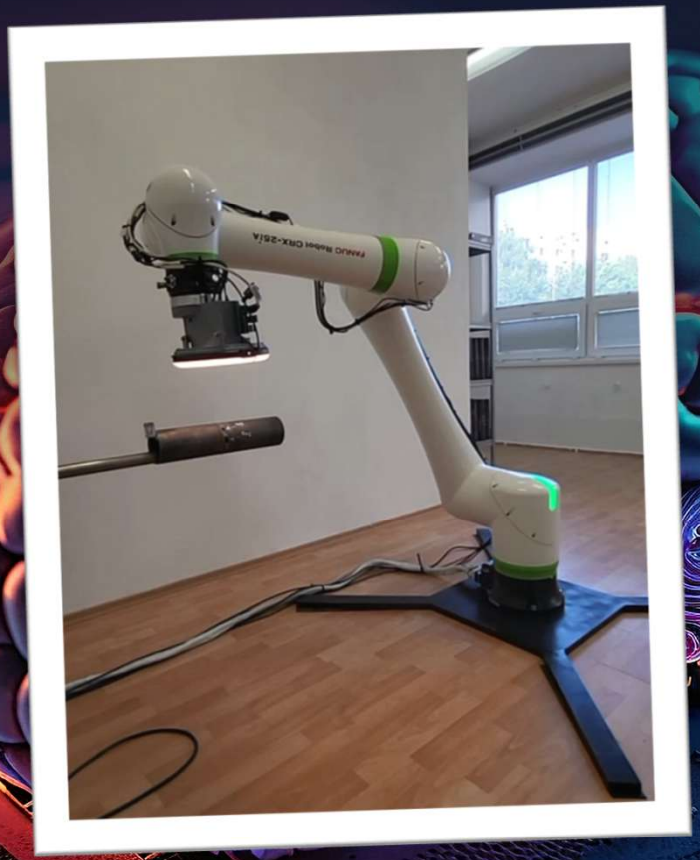
4. **Optimalizujte** parametre HNS a realizujte **trénovanie** a **testovanie viacerých štruktúr** HNS na dátových sadách zvarových defektov

5. **Implementujte** vzniknutý nástroj umelej inteligencie do počítačového systému robotického diagnostického pracoviska.

6. **Vyhodnoťte** dosiahnuté výsledky.



Idea



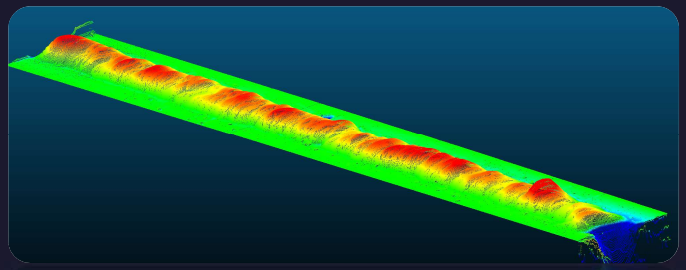


A.I

VUEZ


Procesné dáta

Mračná bodov + Videozáznamy

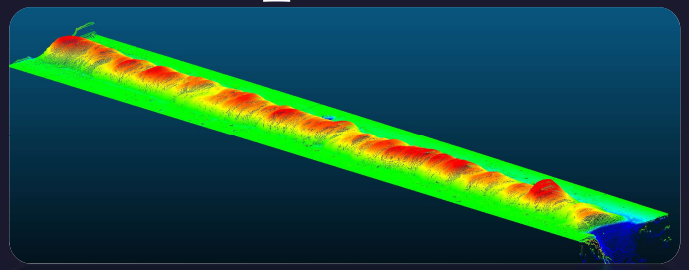


- Skener ScanCONTROL 3000-25/BL
- Geometria vrchu + spodku zvaru
- ČSN EN ISO 5817 farebné kódovanie Z - úrovní
- Surové dáta vo formáte ***.pcd***

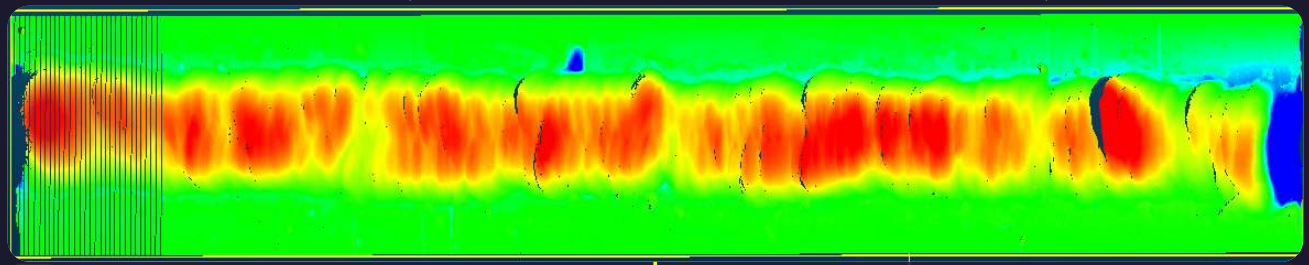


- Raspberry Cam V3
- Vzhľad vrchu + spodku zvaru
- Surové dáta vo formáte ***.mp4***

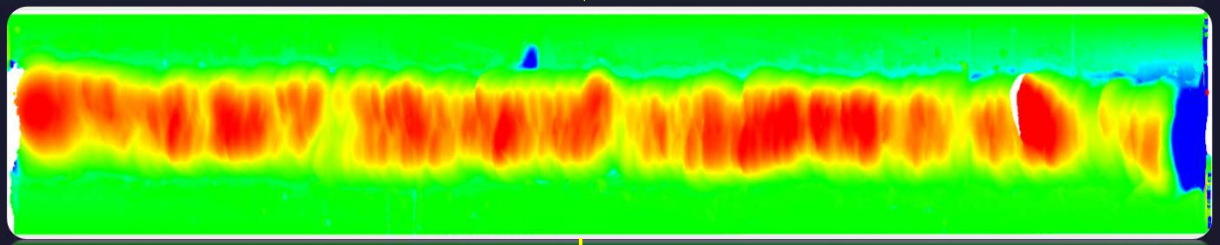
Spracovanie mračien (laser. dataset)



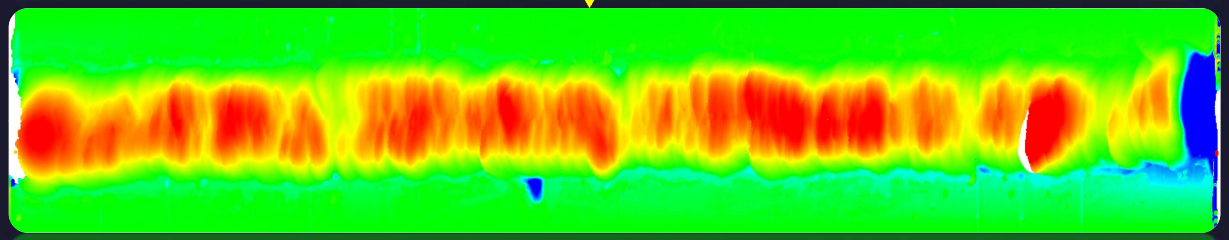
XY projekcia



Pxl / mm = 20 ↓ bodový radius = 4



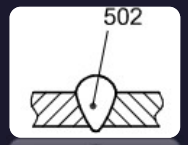
Orezanie tzv. outliers ↓ Zrkadlová rotácia



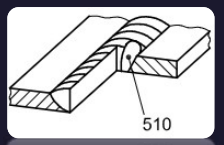
- Výšková mapa (ortogonálna projekcia)
- Odstránenie šumu (zväčšenie rádiusu bodu a doladenie rozlíšenia)
- Odstránenie bielych okrajov a zarovnanie vzhľadom na videozáznam (zrkadlová vertikálna rotácia) + prípadné pridanie zelených okrajov (% - konzistentnosť šírky zvaru)
- Úprava rozlíšenia na „dĺžka zvaru × 400“

Kategorizovanie vzoriek

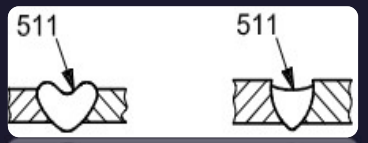
- Posuvné okno „400 × 400“ s posuvom 50 px
- Primárne 2 rôzne fázy klasifikácie , tj. uvažované 2 rôzne charaktery datasetov:
  - Dobrá , resp. zlá vzorka (tj. defekt)
  - 6 tried defektov podľa EN ISO 6520
- Cieľ: Pôvodný rúrkový dataset + manuálne označené (ručné) plechové zvary



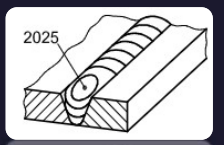
Prevýšenie zvaru



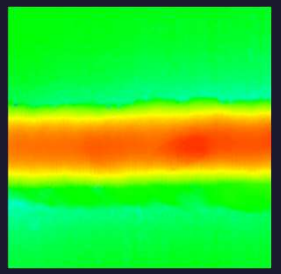
Diera

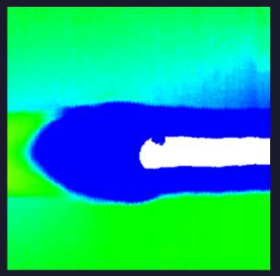


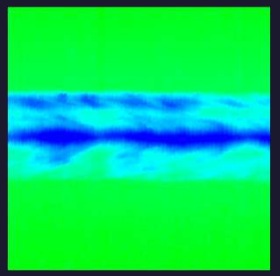
Prehĺbený zvar

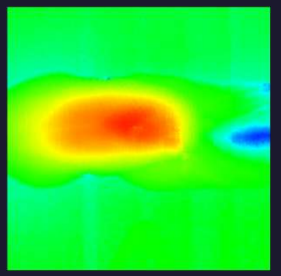


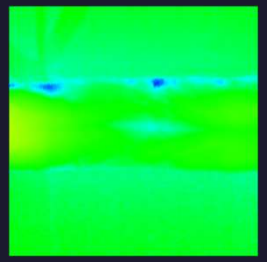
Kráterový lunker

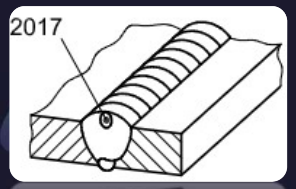




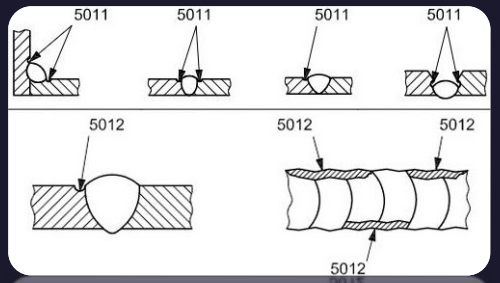


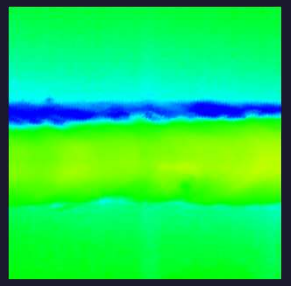






Povrchový pór





Súvislý a prerušovaný zápal

Revidácia pôvodného datasetu

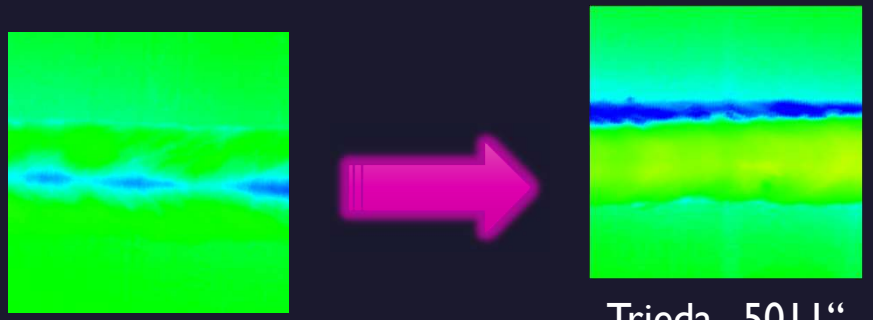
- Kritické - prioritizácia – nutné odbor. konzultácie
- Nový prístup pre defekty :

4 – tried. model

5 – tried. model [*]

- Trieda „2025“, resp. kráterových lunkerov identifikovaná ako špecifická pre povrch zvaru [*]
- Zrušenie triedy „2017“, resp. zlúčenie povrchového póru do triedy zápalov





Spracovanie videozáznamov

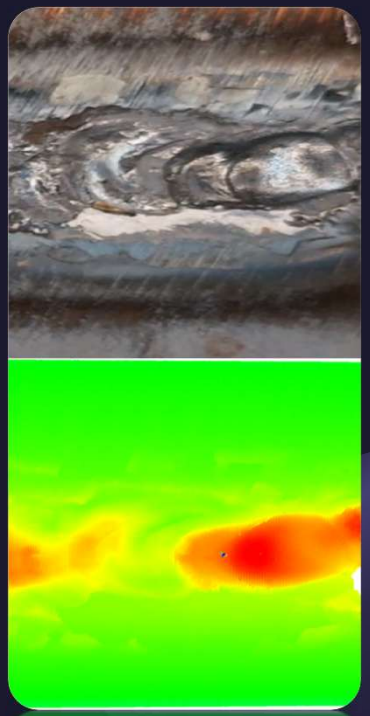
- Zabezpečená *priestorová fúzia* - kamery a laser skeneru
- Princíp *panorámy*
- Detekcia synchronizačných bodov-*START* a *END snímky*
- *CANNY EDGE Detekčné pásy* – každý 6% výšky snímky







Spracovanie videozáznamov - synchronizácia

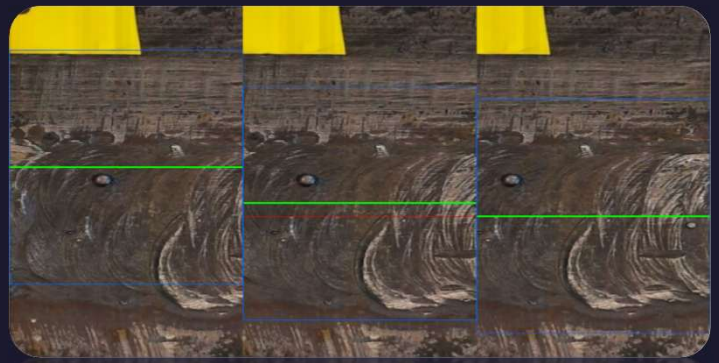


- Skladaná panoráma = počiatočný a koncový snímok + horizont. pásiky :

  - farebne prispôsob. svojmu lokálnemu jas. ref. bodu (vyp. z okolitých snímkov)

  - šírka podľa miery posuvu susedných snímiek

  - prípadná bilineárna interpolácia (kamera sa medzi snímkami posunula napríklad o 0,8 px)



- *Normalizácia* vzhľadom na laserovú projekciu + automatické orezanie prebytočných 200 px (snímok po snímke)



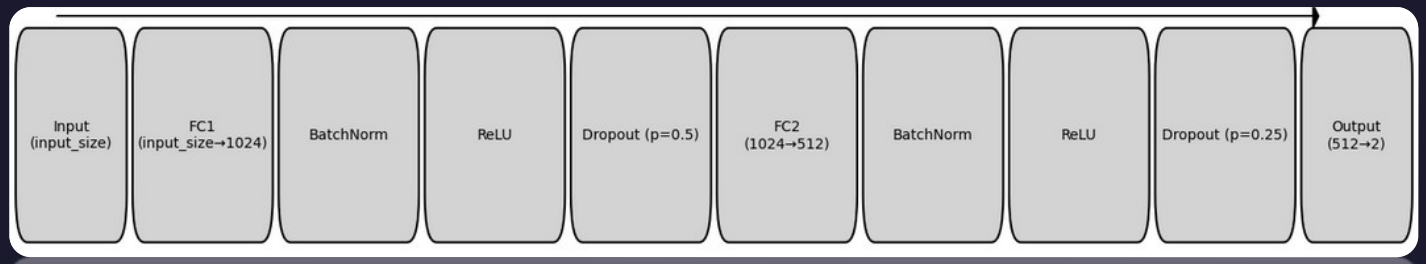
Výstup: synchronizovaný video dataset 400×400 px – každý laser výrez má identický video ekvivalent


Trénovanie
CNN

Transferové učenie na vybranom modely

- Pôvodný 6 triedny model rúr
- Revidovaný 4/5 triedny model rúr
- Neaugumentovaný – (Dotovaný plechmi) 4/5 triedny model rúr
- Augumentovaný - Dotovaný plechmi) 4/5 triedny model rúr
- Využitie regularizačných a váhovacích techník

Upravený klasifikátor EfficientNet-b0



Trieda	Pred augmentáciou	Po augmentácii	Prírastok	Zastúpenie
502	2 313	4 931	+2 618	31.0 %
510	670	670	–	4.2 %
511	3 496	4 586	+1 090	28.8 %
2025	199	199	–	1.3 %
5011	3 595	5 531	+1 936	34.7 %
Spolu	**10 273**	**15 917**	**+5 644**	**100 %**

Balans tried

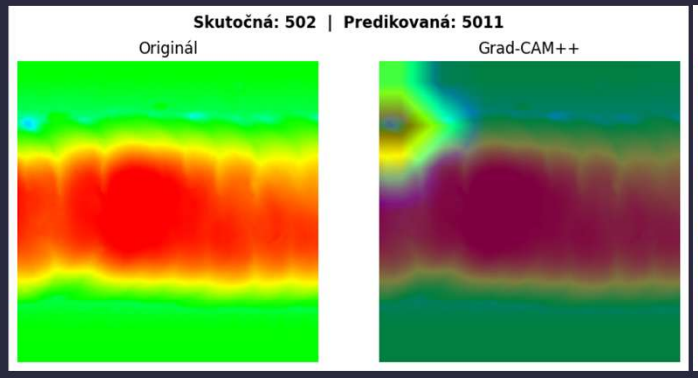
EVOLÚCIA MODELOV – CELKOVÁ PRESNOSŤ

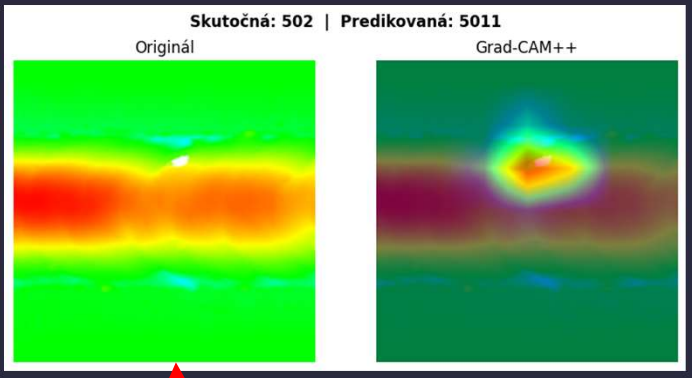
Model	Rúry	Vrch (1xxx)	Spodok (3xxx)	Poznámka
6-triedny (pôvodný)	78.3%	42.5%	43.3%	Obsahuje triedu 2017 (povrchový pór)
Revidovaný 4/*5-triedny	*86.2%	*68.7%	87.2%	Trieda 2017 odstránená Duálny model podľa strany
Dotovaný 4/*5-triedny	*88.4%	*95.2%	94.3%	
Augmentovaný 4/*5-triedny	*88.6%	*94.8%	93.6%	15 917 vzoriek celkom Náhodné 2/10 augmentácií

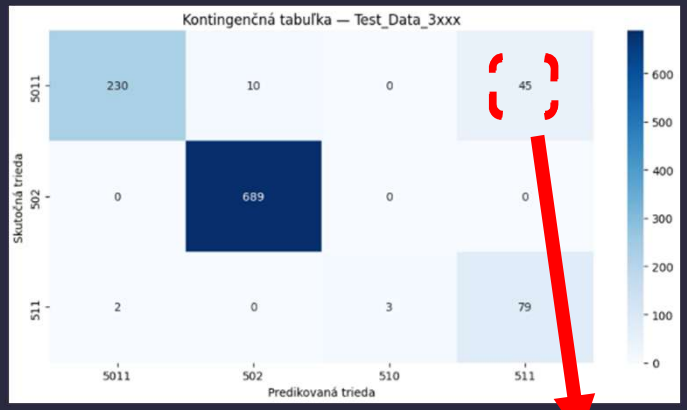
Najvýraznejší posun: vrch plechov +26.5 % (42.5 % → 95.2 %) po dotovaní plechovými vzorkami

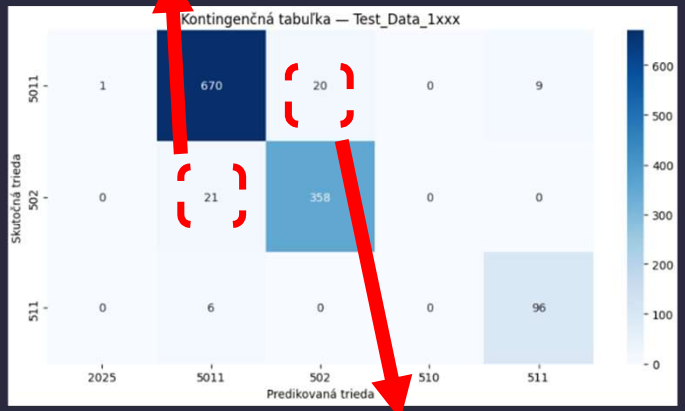
Interpretácia výsledkov

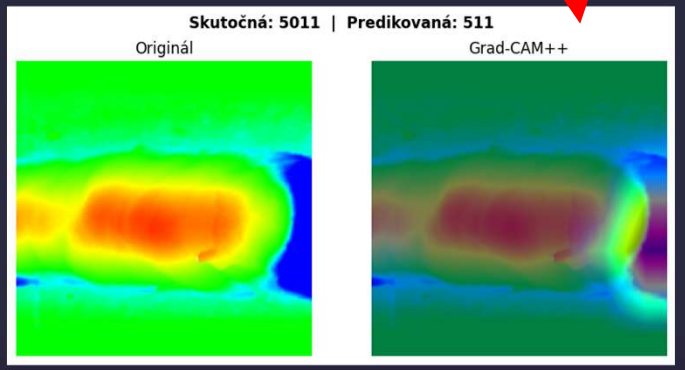
dotované modely

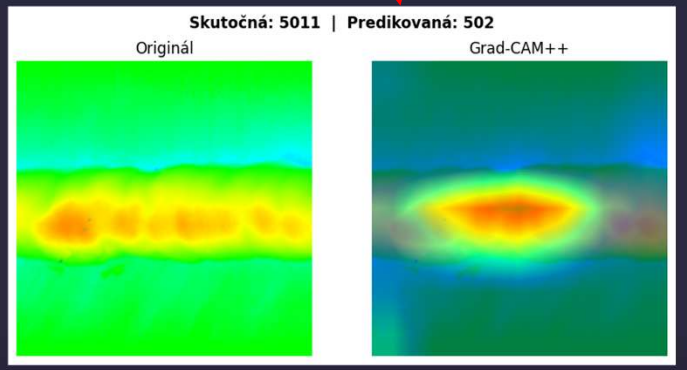










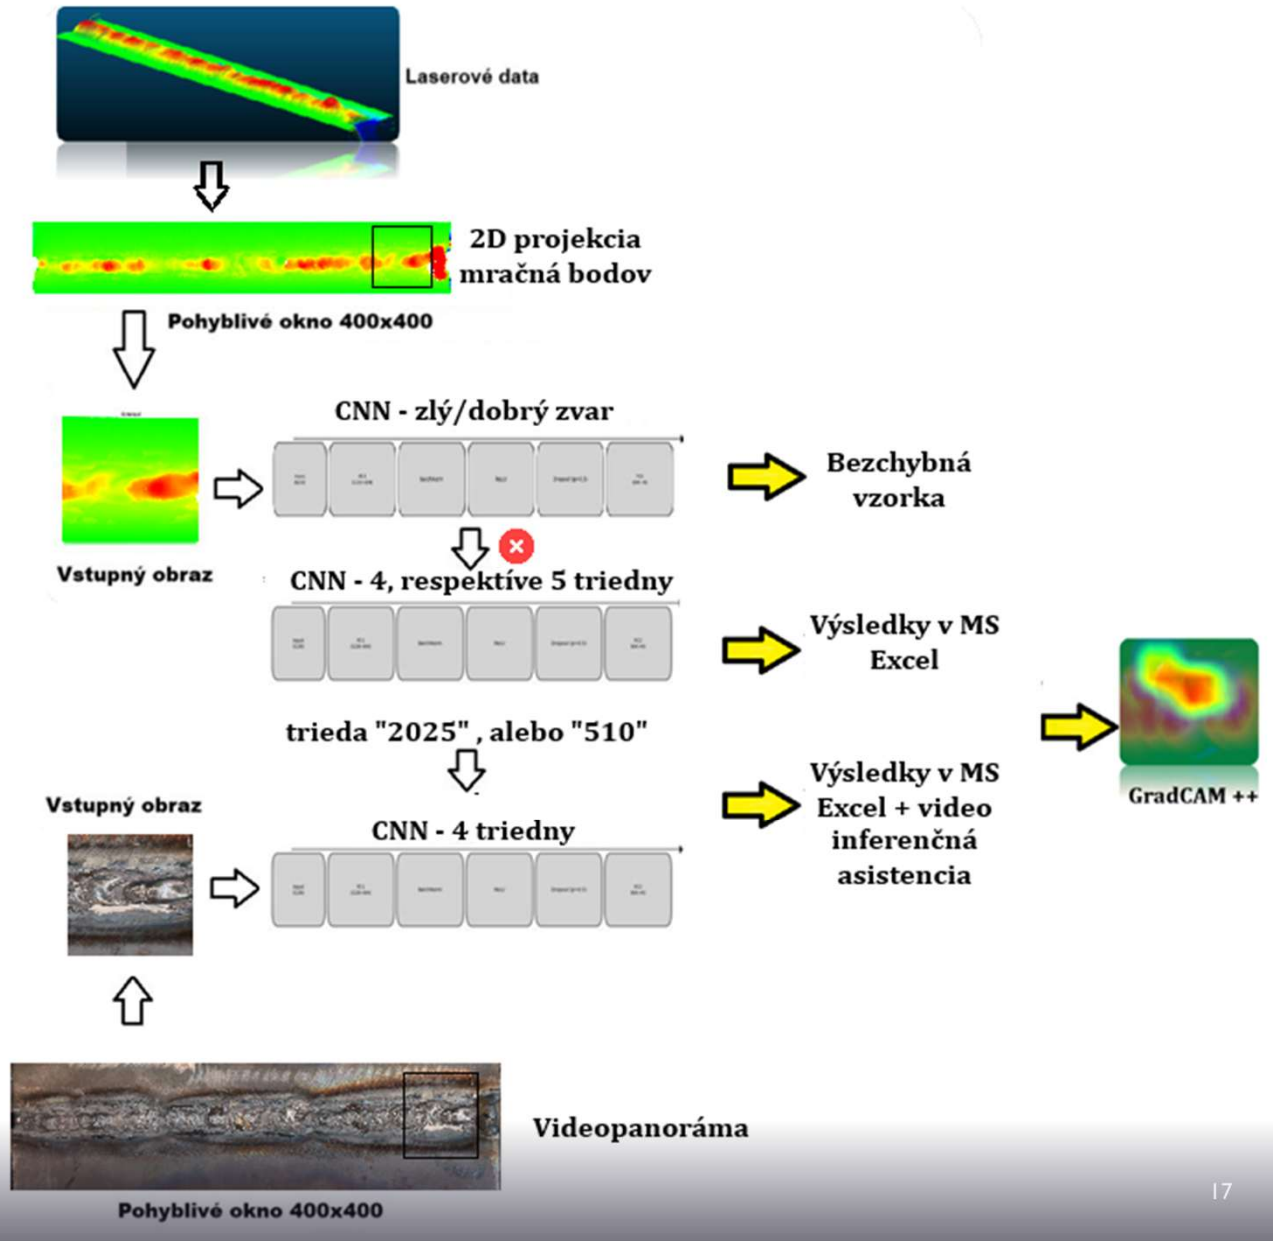


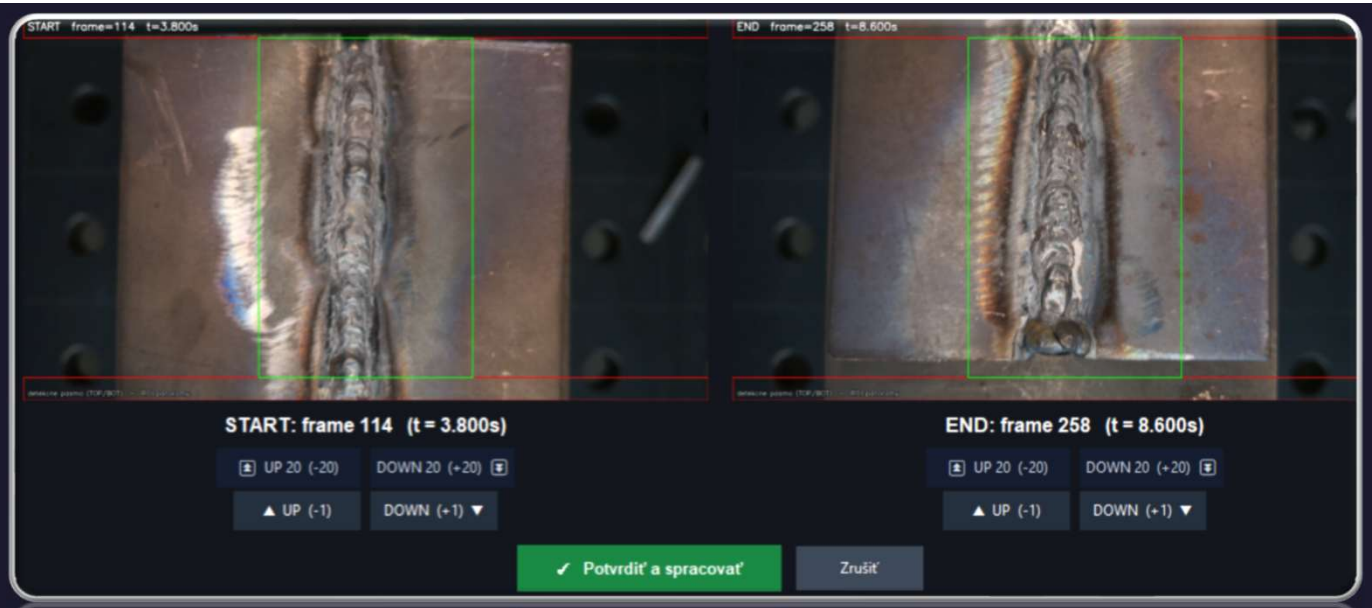

Implementácia

Výsledný klasifikačný workflow

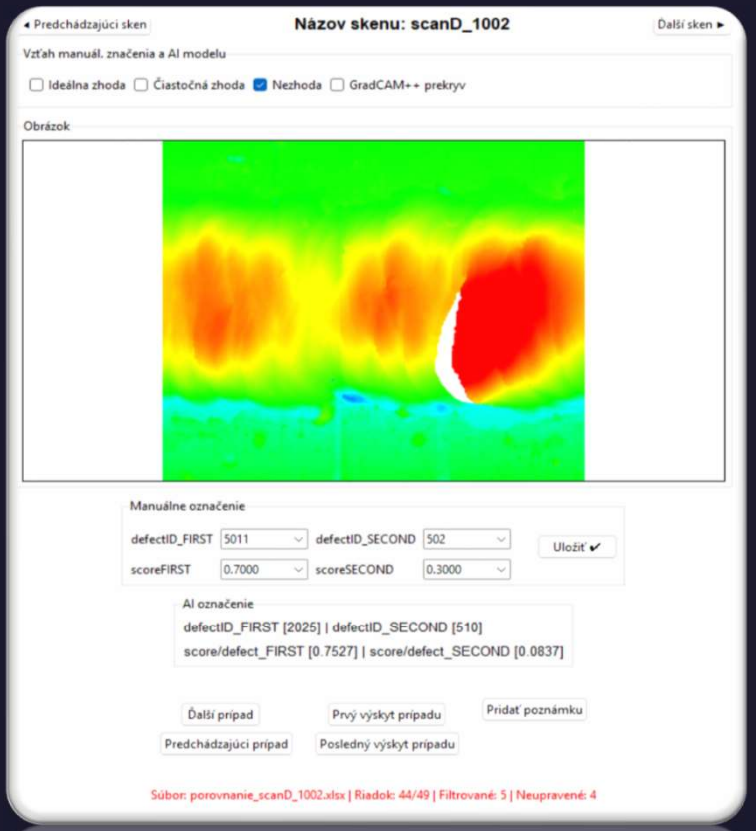
- Python script
- Vstupný argument - mračno bodov vybraného obrobku, prípadne setu
- Výstup Excel tabuľka + GradCAM++ na debug
- 2x EfficientNet-B0 siete pre 2-stupňovú laserovú klasifikáciu
- Asistenčná ResNet18 pre videoverifikáciu

Vrch plechu: 5-triedny model (511, 5011, 502, 510, 2025)
Spodok plechu: 4-triedny model (511, 5011, 502, 510)





GUI – Ladiaci režim synch. bodov na spracovanie videopanorámy



GUI – Revízna aplikácia

Vytvorené asistenčné nástroje a hierarchia

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y
crop_id	class / 1-bad 0-good	score / class	defectID_FIRST	score/defect_FIRST	defectID_SECOND	score/defect_SECOND	prediction / class	score / class	defectID_FIRST	score/defect_FIRST	defectID_SECOND	score/defect_SECOND		binary corect	binary corect 2	binary uncorect	ACC binary	ACC2 binary		defect corect	defect corect2	defect uncorect	ACC defect	ACC2 defect
0	1	1,0000	5011	0,7000	502	0,3000	0		0	1,0000	0	0,0000		0	0	1	0,9861	0,9861		0	0	1	0,6111	0,9861
1	1	1,0000	5011	0,7000	502	0,3000	1	0,9516	502	0,4843	5011	0,2300		1	0	0				0	1	0		



Potenciálne navrhované kroky zlepšenia

Ďakujem za pozornosť



