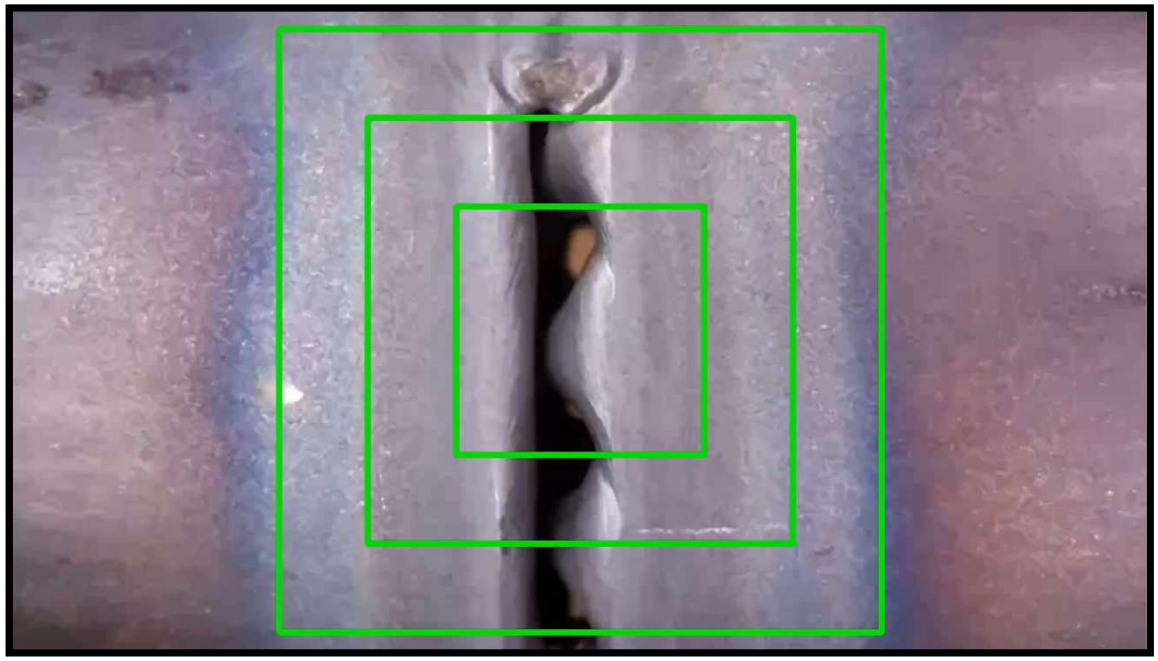
KLASIFIKÁCIA DEFEKTOV ROBOTMI REALIZOVANÝCH ZVAROV AI NÁSTROJOM

- Študent: Denis Švec
- Vedúci práce: Ing. Slavomír Kajan, PhD.
- Konzultant: Ing. Zuzana Kovaríková, PhD.

Anotácia

- Táto práca sa zaoberá vytvorením nástroja na báze umelej inteligencie ktorý dokáže klasifikovať defekty zvarov. Detekciu defektov budeme vykonávať zo snímok z videozáznamov. Videozáznamy nám boli poskytnuté spoločnosťou VUEZ a.s. s ktorou spolupracujeme na tomto projekte.



Vid. Modifikované video zvaru

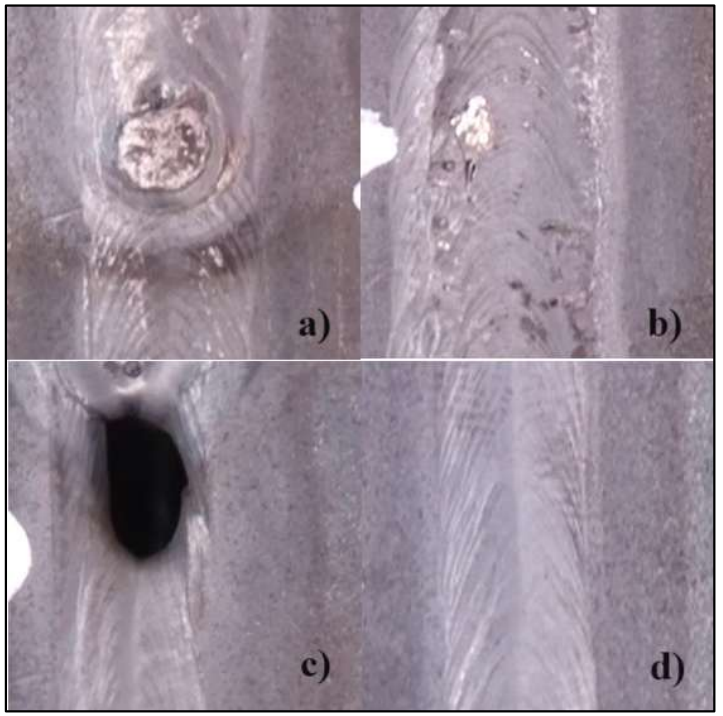
Úlohy

- 1. Naštudovanie možnosti klasifikácie zvarov s využitím nástrojov umelej inteligencie.
- 2. Navrhnutie nástroj na báze umelej inteligencie pre klasifikáciu zvarových defektov na základe fotografií robotmi realizovaných zvarov.
- 3. Otestovanie navrhnutý nástroj pomocou testovacej sady fotografií zvarových defektov.
- 4. Verifikácia navrhnutý AI nástroj pre aktuálne zrealizované zvary.
- 5. Vyhodnotenie dosiahnutých výsledkov.

Vytvorená dátová sada

- Triedenie dát podľa štandardizácie na ID chýb
  - a) 2025 - Kráterový lunker
  - b) 500 - Chybný tvar vonkajšieho povrchu
  - c) 510 - Diera
  - d) OK - Vyhovujúce časti zvaru

- Augmentácia: Zrkadlenie, Šum, Rotácia, Posun snímky



Obr. 1 Snímky z dáta setu

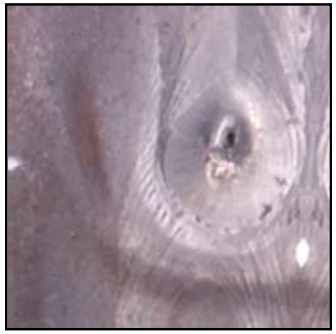
Dátová sada

- Augmentované dáta z 215 video záznamov
- Dataset bol rozdelený podľa video záznamov

Tab. 1 Dátová sada

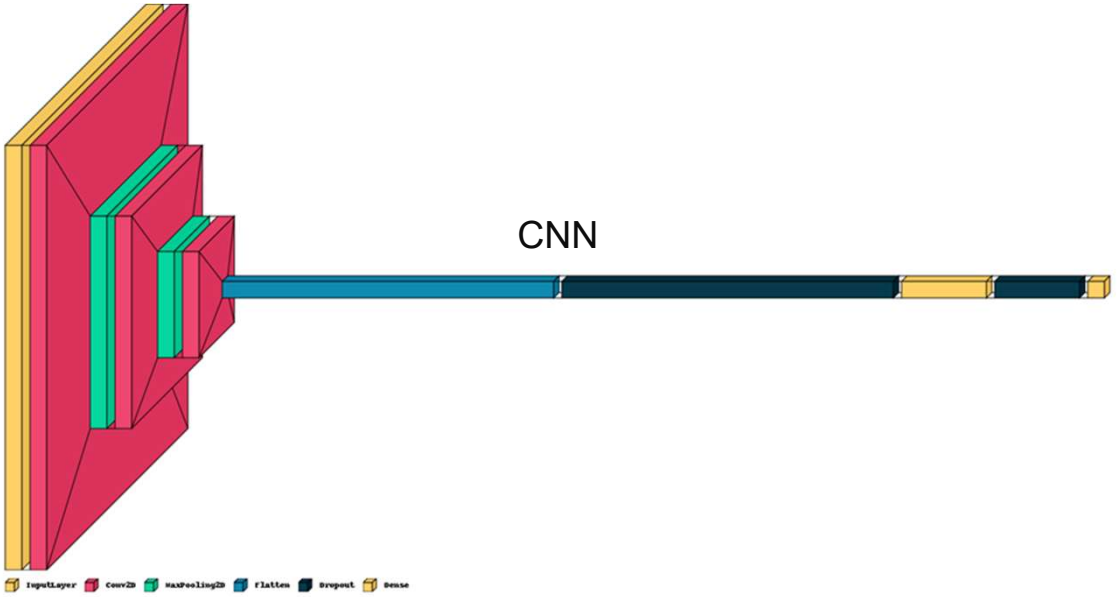
ID	TEST DATA	TRAIN DATA
500	437	1 867
510	5 661	16 113
2025	1 165	6 662
OK	5 670	10 200

Princíp klasifikácie defektov zvarov pomocou konvolučnej neurónovej siete



Snímka

Input



Output trieda

Obr. 2 Konvolučná neurónová sieť pre klasifikáciu defektov zvarov

Výsledky testovania

- TP – Skutočné pozitívum (True Positive)
- FP – Falošné pozitívum (False Positive)
- TN - Skutočné negatívum (True Negative)
- FN - Falošné negatívum (False Negative)

$$\mathrm{ACC} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\mathrm{F}_1 = \frac{2TP}{2TP + FP + FN}$$

ID chýb

Štatistika	Presnosť (PPV)				Úspešnosť (ACC)
	2025	**500**	**510**	**OK**	**Priemer**
Sériová	93.99%	46.45%	99.65%	99.45%	97.31%
Paralelná	90.82%	66.13%	99.74%	98.14%	97.14%
AlexNet	97.25%	93.14%	**99.90%**	98.31%	98.74%
ResNet18	99.57%	94.97%	99.84%	99.51%	99.51%
Inception v3	**99.74%**	90.16%	99.79%	98.89%	99.07%
MobileNet v3	99.31%	**96.80%**	99.81%	**99.74%**	**99.64%**

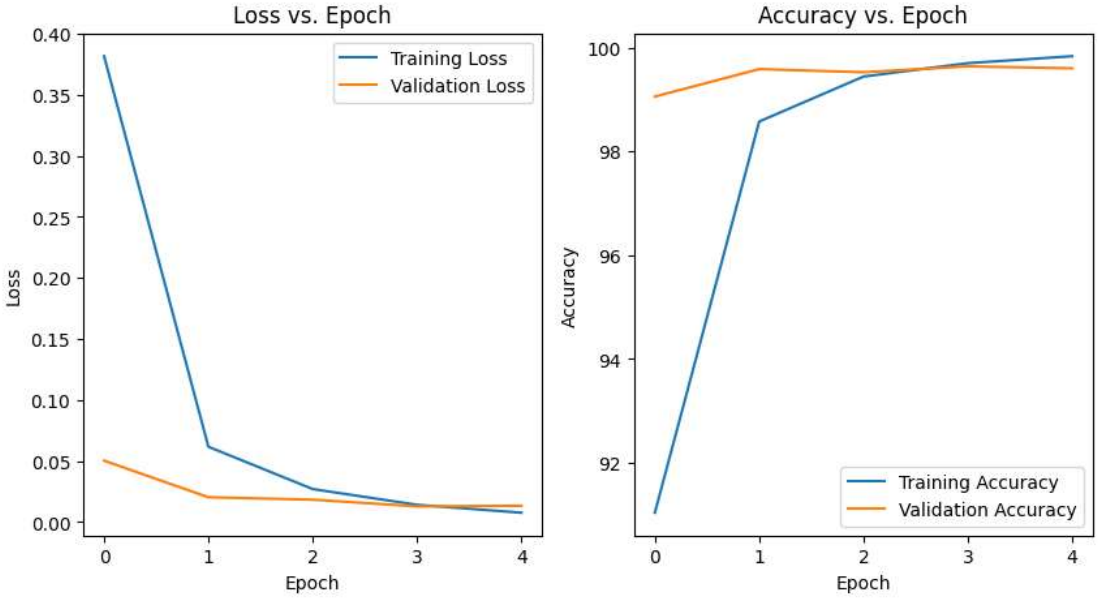
ID chýb

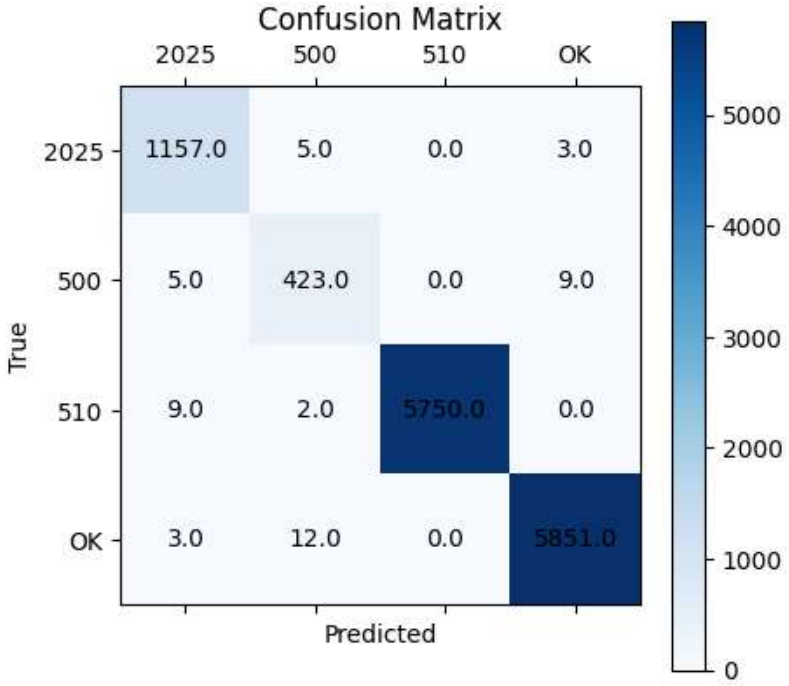
Štatistika	F1			
	2025	**500**	**510**	**OK**
Sériová	91.02%	58.00%	99.83%	98.46%
Paralelná	92.20%	62.55%	99.87%	98.14%
AlexNet	97.76%	84.53%	99.89%	98.97%
ResNet18	**99.10%**	94.21%	**99.92%**	99.58%
Inception v3	98.31%	89.75%	99.89%	99.12%
MobileNet v3	98.93%	**96.25%**	99.90%	**99.77%**

Tab. 2 Výsledky CNN

Výsledky MobileNet v3

- Epochy: 5
- Chybová funkcia: CrossEntropyLoss
- Optimalizér: Adam
- Krok učenia: lr=0.00001
- Veľkosť batchu: 32
- Počet zopakovania experimentu: 3





Obr. 3 Kontingenčná tabuľka a chybová funkcia CNN

Detekcia defektov zvarov

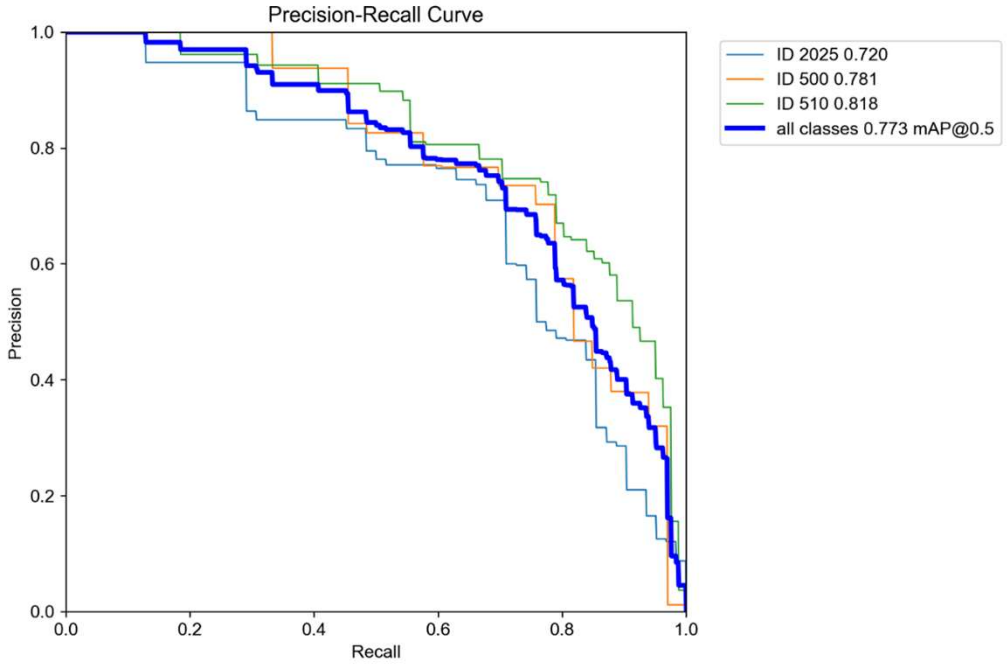
- Detekcia triedy a pozície defektov zvarov pomocou YOLOv5 a Faster R-CNN detektorov
- Polohu daného objektu identifikujeme pomocou obdĺžnikového rámčeka.



Obr. 4 Detekcia objektov pomocou YOLOv5

Výsledky detekcie defektov zvarov

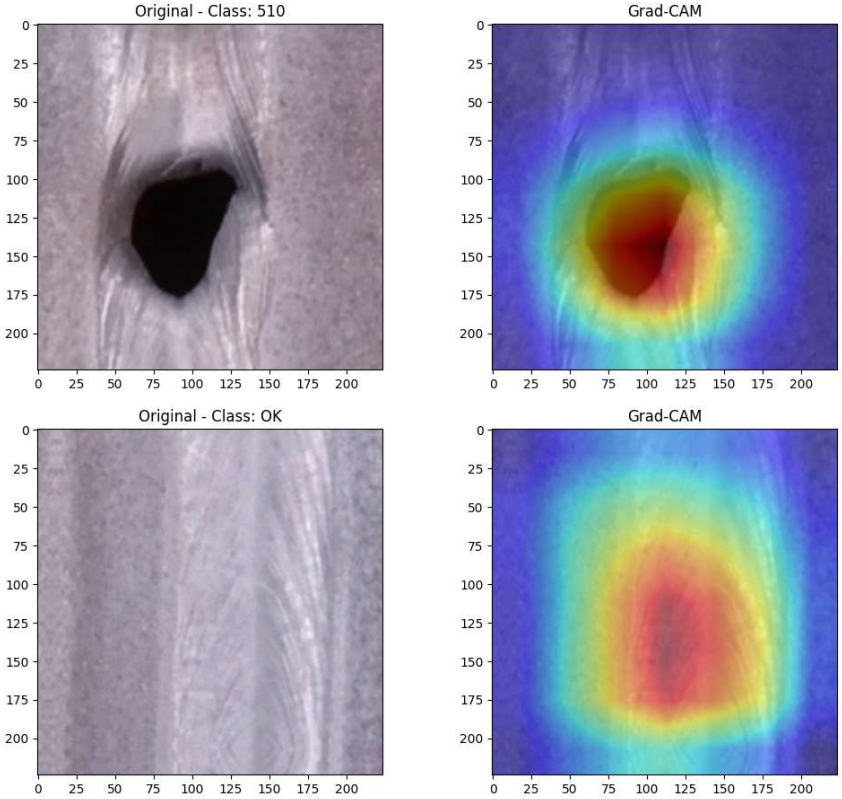
- Precision-Recall je graf, ktorý zobrazuje výkonnosť klasifikačného modelu pri rôznych klasifikačných prahoch. Táto krivka sa používa na vyhodnotenie kompromisu medzi presnosťou pozitívnych predpovedí a schopnosťou modelu identifikovať všetky skutočné pozitíva.
- Metrika mAP pre všetky triedy spolu je 0,773.



Obr. 5 Priebeh mAP pre YOLOv5 detektor

Vizualizácia CNN – metóda GradCAM

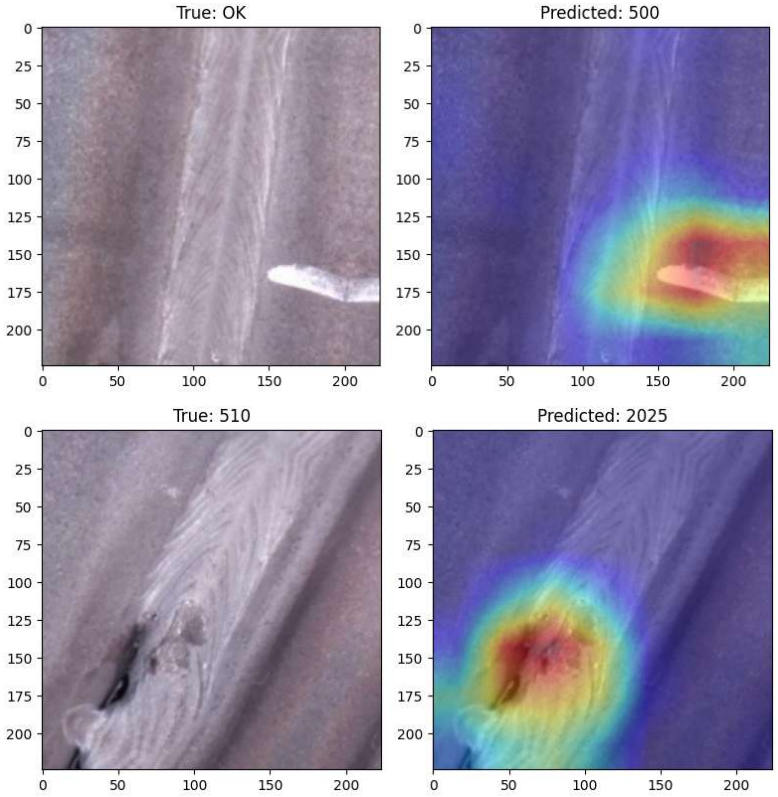
- Slúži na generovanie tepelných máp, na ktorých vidíme rozhodovací proces modelov hlbokého učenia
- Tepelnú mapu vytvára skúmaním gradientových informácií prúdiacich do konečnej konvolučnej vrstvy CNN
- Pri správnej klasifikácie defektu sú označené oblasti defektov, pri triede dobrý zvar je to celá oblasť zvaru.



Obr. 6 Vizualizácia CNN – GradCAM metóda

Analýza chybných detekcií

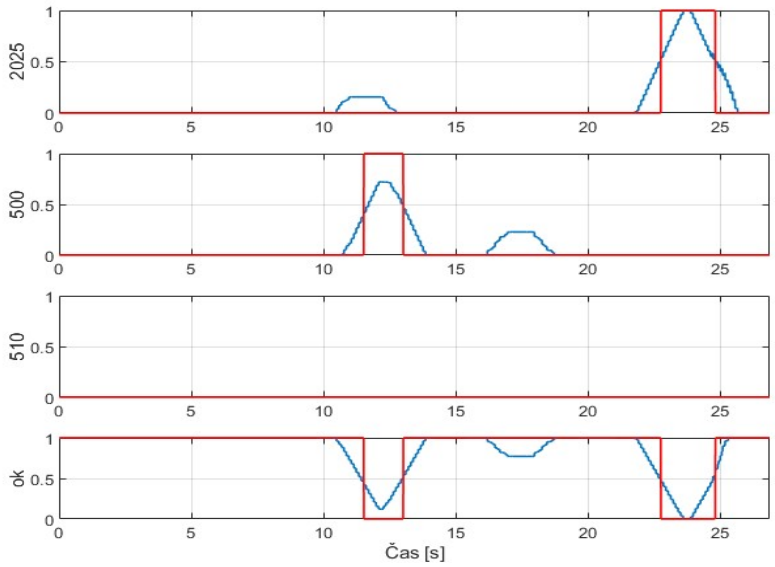
- Analýza chýb cez metódu GradCAM.
  - Občasná falošná detekcia chyby pri detekcií bielej farby
  - Zlá detekcia defektov s malým množstvom dát
  - Zlá detekcia pri vzhľadovo podobných defektoch
  - Neschopnosť detegovať chyby, ktoré sa prejavujú len zmenou výšky zvaru



Obr. 7 Vizualizácia CNN – GradCAM metóda

Detekcia z videa pomocou CNN

- Na obrázku vidíme ID jednotlivých tried ktoré detegujeme, hranicu detekcie sme nastavili na 50% istoty detekcie.



Obr. 8 Detekcia defektov v čase videa

