

Experimentálne porovnanie metód hlbokého učenia pre vizuálnu inšpekciu defektov

Autor : Bc. Peter Palček

Konzultant: Ing. Slavomír Kajan, PhD.

Stručný obsah

- Motivácia & problém
- Dataset
- Prehľad prístupov
- Architektúry a ich výsledky
- Zhrnutie dosiahnutých výsledkov

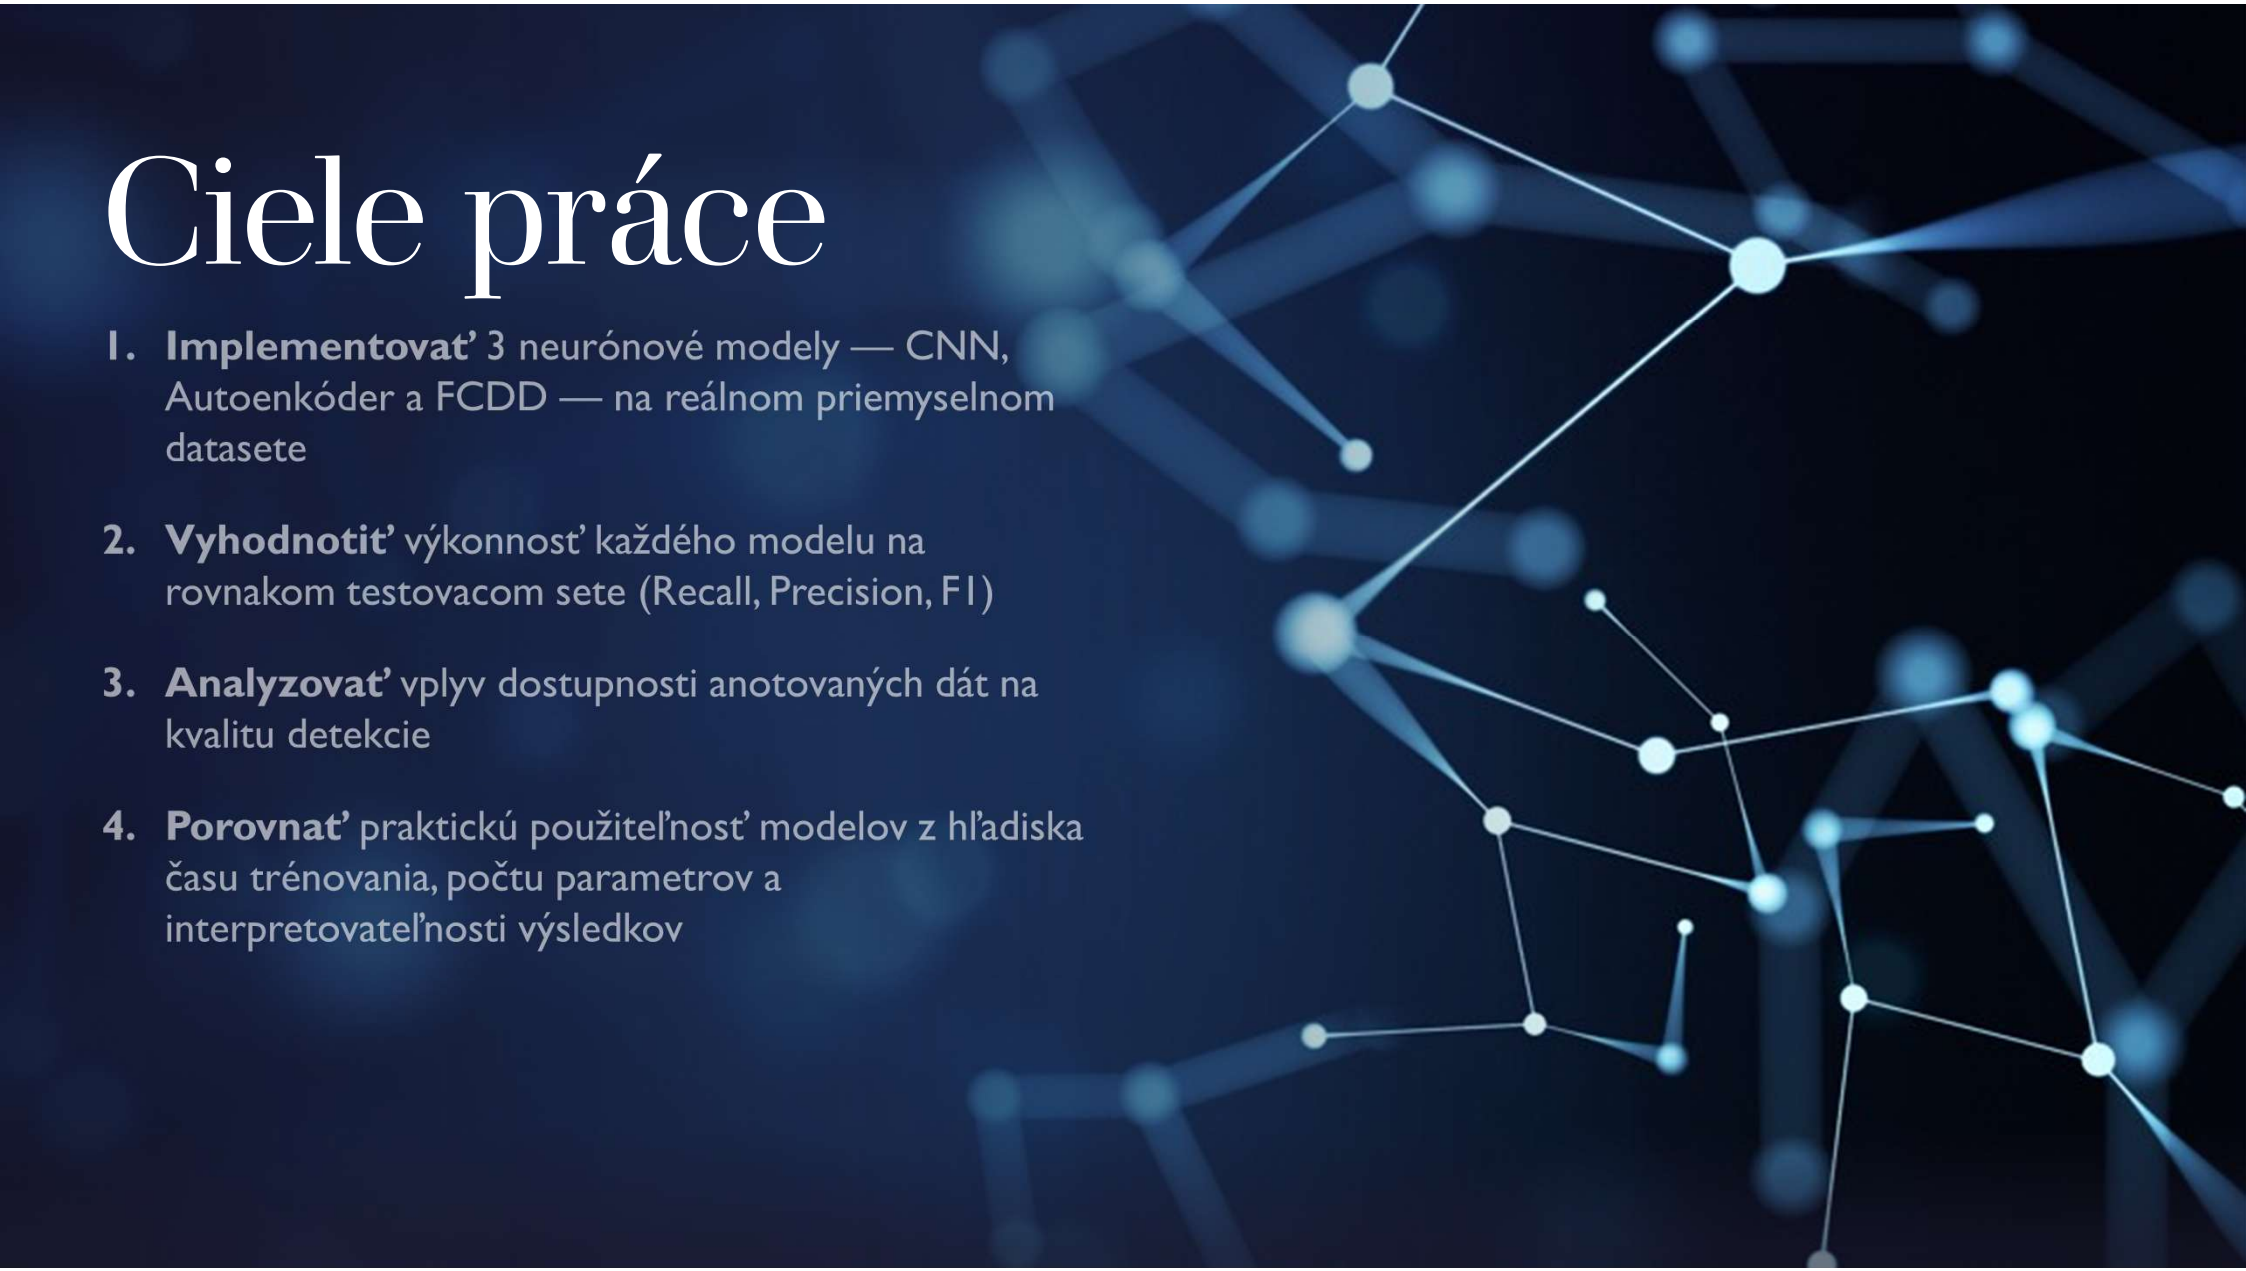






Ciele práce

1. **Implementovať** 3 neurónové modely — CNN, Autoenkóder a FCDD — na reálnom priemyselnom datasete
2. **Vyhodnotiť** výkonnosť každého modelu na rovnakom testovacom sete (Recall, Precision, F1)
3. **Analyzovať** vplyv dostupnosti anotovaných dát na kvalitu detekcie
4. **Porovnať** praktickú použiteľnosť modelov z hľadiska času trénovania, počtu parametrov a interpretovateľnosti výsledkov



Idea






Dataset

„casting product image data for quality inspection“ z Kaggle

- **Odliatky** - vrchný záber na povrch obežných kolies čerpadiel
- **300×300** px
- **Offline augmentácia** aplikovaná autormi
- Monochromatické – Grayscale
- **ok_front** a **def_front** triedy - 10 % ok a 20% def. na kalibráciu/validáciu
- 100% a 1%, respektíve 5% defektných na trén.
- Testovací set **nedotknutý** - prevencia data leakage

Učiteľ : **prítomný** I **z časti** I **absentuje**

Set	CNN	FCDD	Autoenkóder
Trénovací ok_front	2587	2587	2587
Kalibračný ok_front	-	288	288
Validačný ok_front	288	-	-
Testovací ok_front	262	262	262
Trénovací def_front	3006	30, resp. 150	-
Kalibračný def_front	-	752	752
Validačný def_front	752	-	-
Testovací def_front	453	453	453


Trénovanie

Proces trénovania

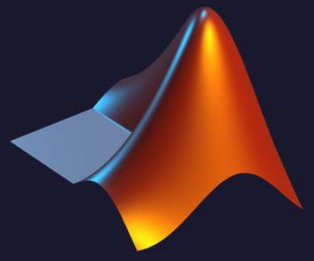
- Early stopping mechanizmus
- Počet epoch bol zvolený zámerne nízky — minimalizácia rizika pretrénovania, najmä pri transfer learningu
- Sieťovo špecifické nastavenia (stratová funkcia, adaptívny LR scheduler) sú odlišné pre každý model

Parametre	Voľba
Počet epóch	20
Veľkosť dávky	32 vzoriek
Premiešanie (epocha)	trénovanie aj validácia
Optimalizátor	Adam
Krok učenia	1e-3
Ohyb momentu grad.	0.9
Ohyb štvorca grad.	0.999
Epsilon	1e-7
L2 regularizácia	-

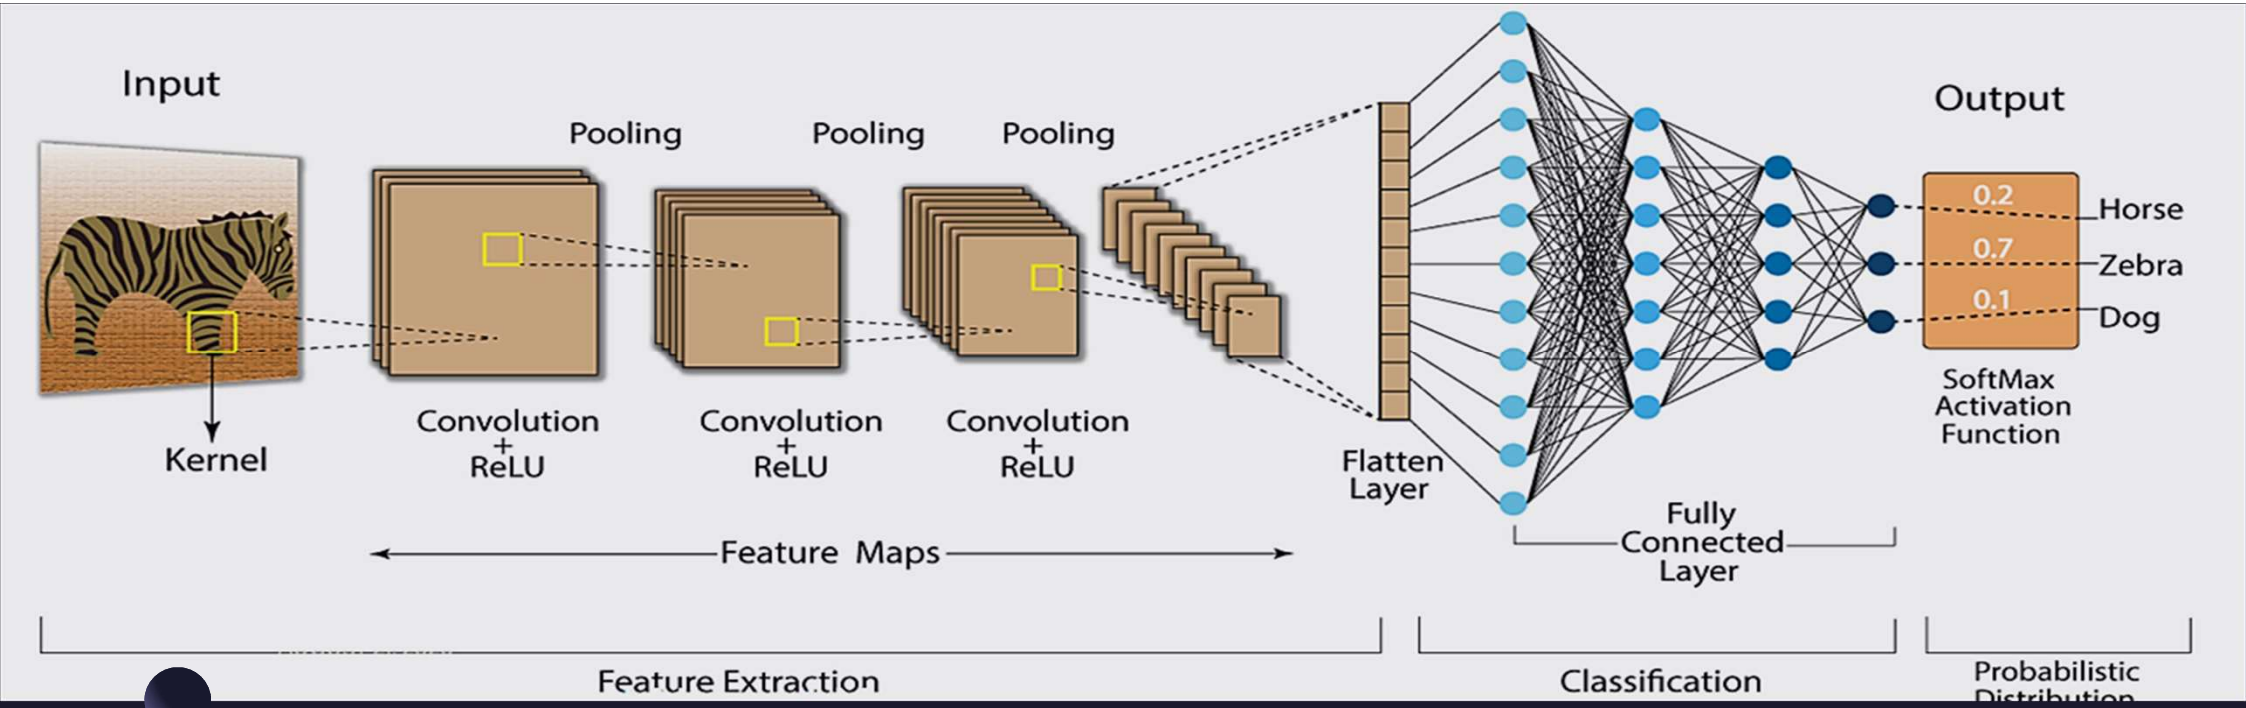
Výskumné zariadenie ÚRK FEI STU :

Komponent	Model
OS	Ubuntu 24.04.3 LTS
GPU	NVIDIA GeForce RTX 5090 (cuda)
CPU	AMD Ryzen Threadripper PRO 5995WX
Operačná pamäť RAM	128 GB DDR4
Pamäť SSD	1 TB NVme





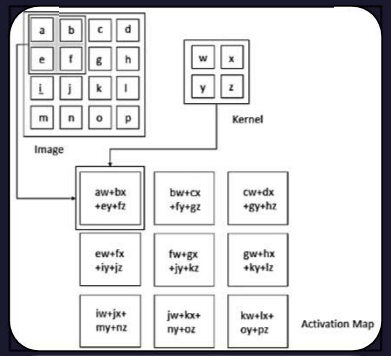

Využívané
prístupy



CNN sieť

- Mozog cicavcov – spracovanie obrazu
- Konvolučné vrstvy + nelineárna funkcia (ReLU, Sigmoid, ...)
- Zhlukovacie vrstvy (maximum, priemer)
- Plne prepojené vrstvy
- Dropout vrstvy (opatrenie proti zafixovaniu sa na jednoduchých príznakoch)

Konvolúcia jadrom 2x2



Zhlukovanie



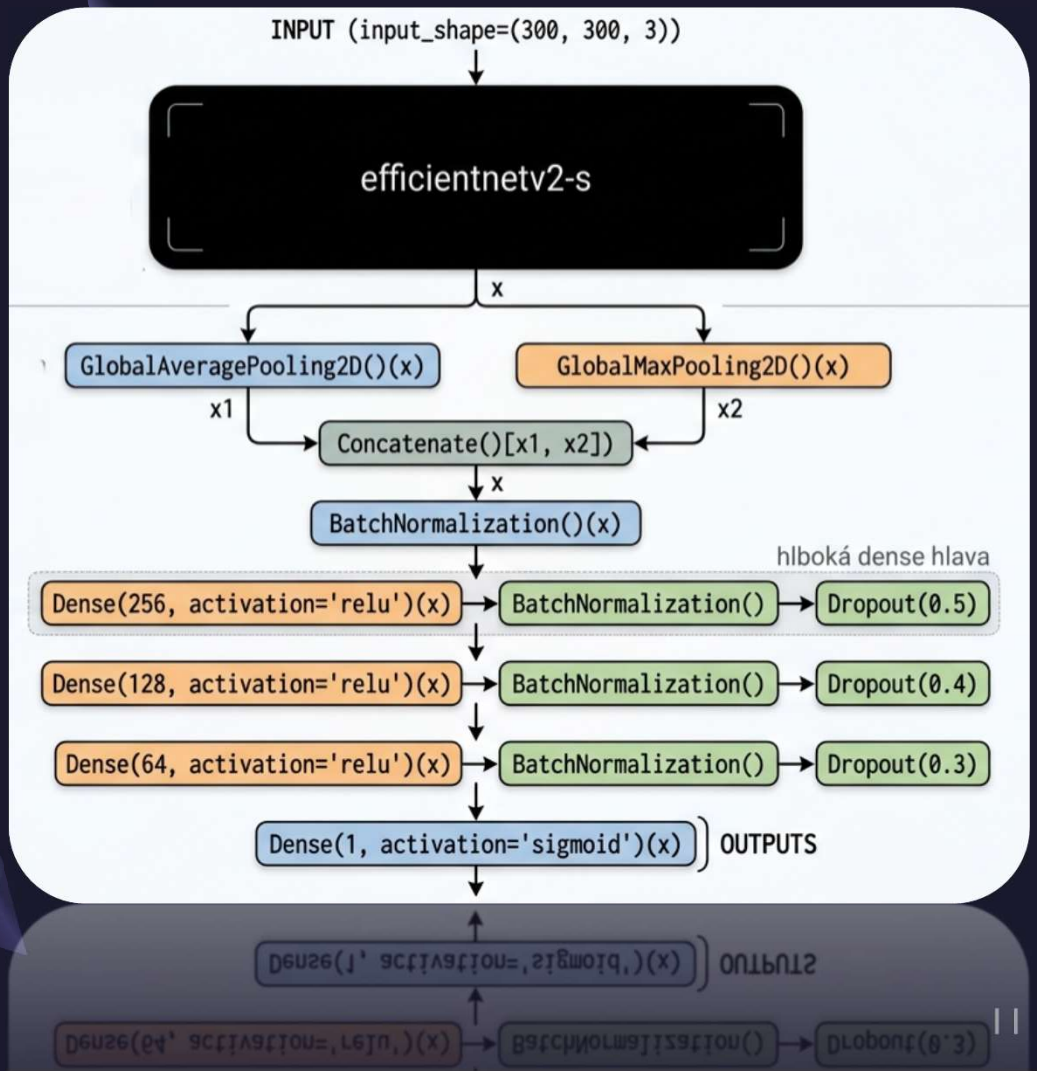
Realizácia

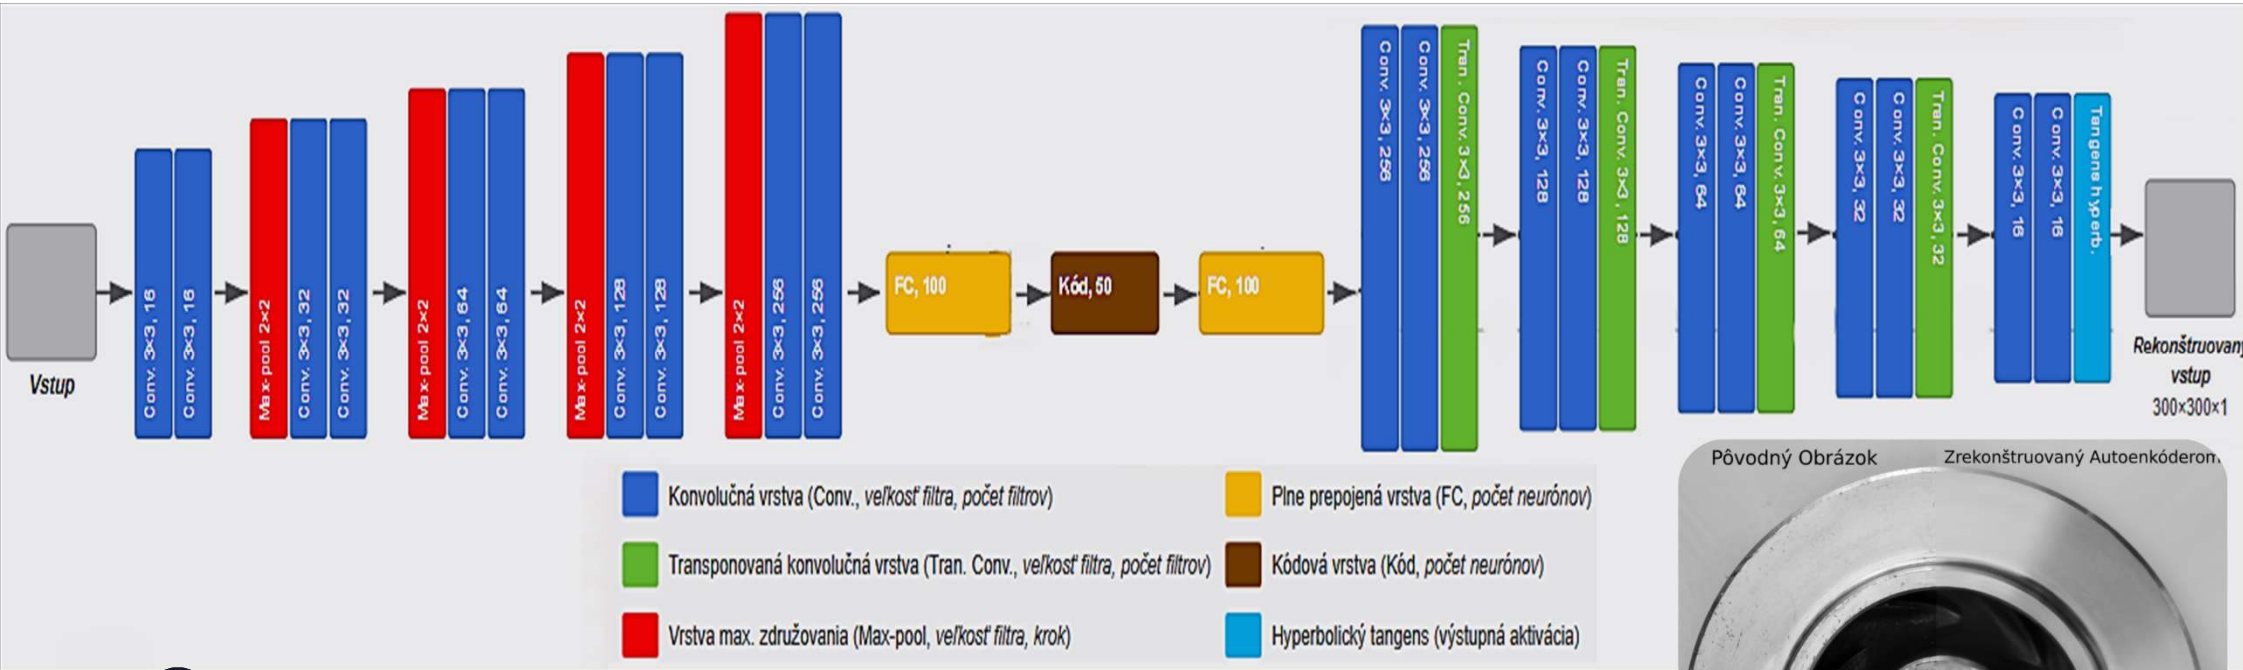
- Binárna klasifikácia – krížová entrópia
- Efficientnetv2-s ako backbone s 21,4M parametrov, natívne pracuje s 384x384 px a natrénovaná na ImageNet1k
- Vlastná hlava siete :

Kombinované zhlukovanie - širší kontext :
max pooling (najvýraznejšie črty)

average pooling (celkový kontext objektu)

- Transferové učenie – 2 fázy – 40 % tréningu iba hlava siete a následne fine tunnig (ladenie) vrchných vrstiev backbone

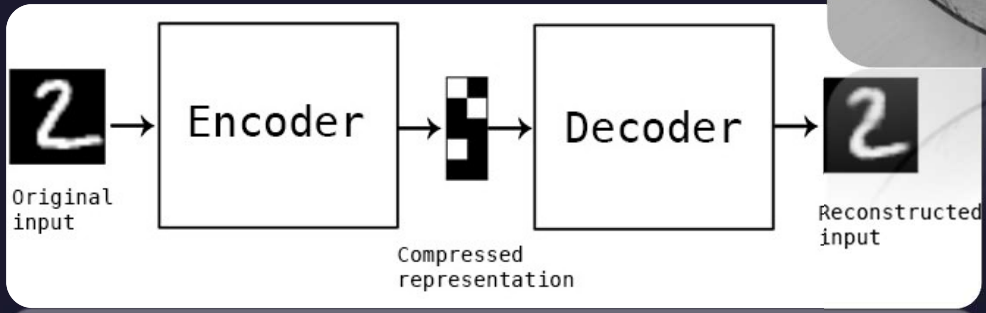


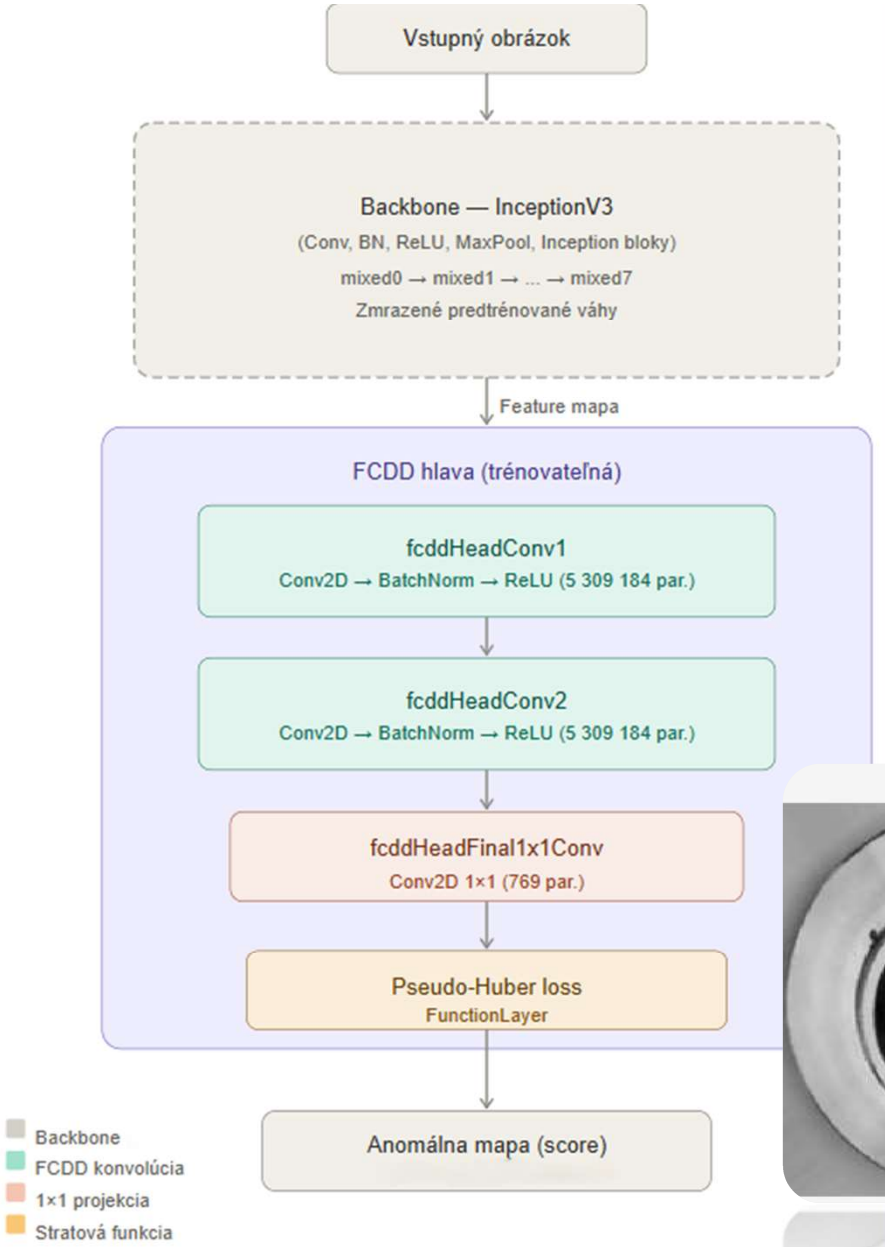




Autoenkóder – gener. kompresia

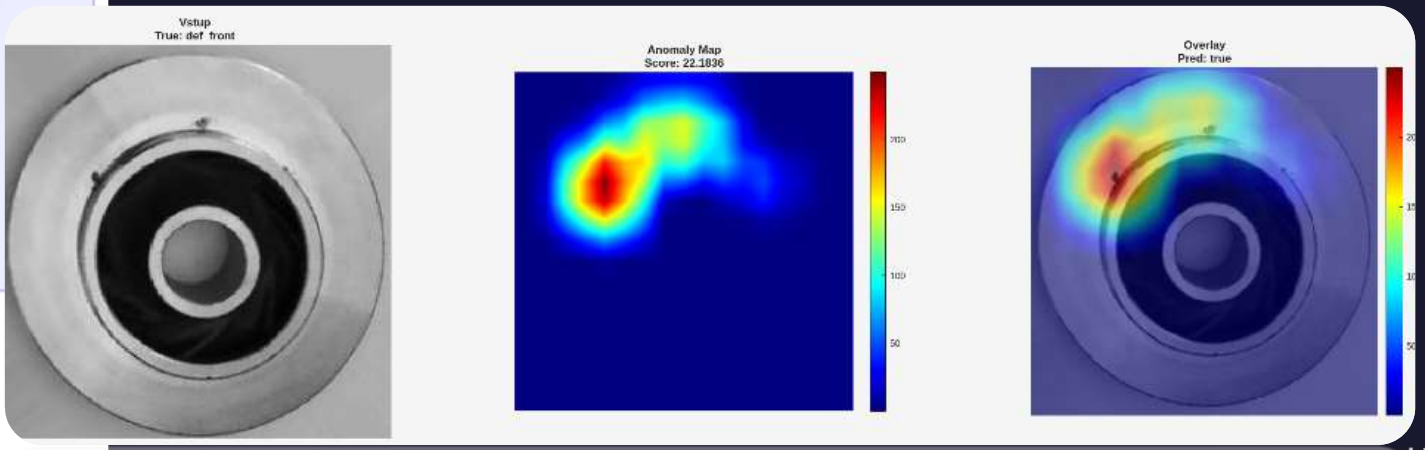
- Princíp spracovania – kvázi presýpacích hodín – enkóder, latentný priestor , dekóder
- Enkóder komprimuje obraz → Kód 50 neurónov (kompresia 1800:1)
- Dekóder rekonštruuje → porovnáva s originálom cez MSE. Symetricky rozbaľuje reprezentáciu cez transponované konvolúcie späť.
- Normálna vzorka → nízka rekonštrukčná chyba
- Defektná vzorka → vysoká chyba → označená ako anomália





FCDD sieť

- Backbone: Inception-v3 — 23.9M parametrov pôvodne — váhy ImageNet1k
- Natívne rozlíšenie 299×299 px, interná normalizácia
- Využité 4 z 5 úrovní downsampling — zachovaná priestorová informácia
- Backbone extrahuje príznaky → hlava FCDD ich premietne cez 2 konvolučné vrstvy → finálna 1×1 konvolúcia → skalárne skóre pre každý pixel
- Výstup: mapa anomálií — každý pixel hovorí nakoľko sa daná oblasť odchyľuje od normálu



Kalibrácia sietí

Nízka stratová funkcia po trénovaní ≠ kvalitný detektor

Model produkuje skóre — potrebujeme hranicu medzi "normálne" a "defekt"

V ideálnom prípade sú distribúcie skóre úplne oddelené — v praxi sa **prekrývajú**

Zníženie prahu → vyšší Recall, nižšia Precision

Zvýšenie prahu → vyšší Precision, nižší Recall

V priemysele - **kritickejší Recall**

Vykresliť distribúcie skóre normálnych a anomálnych vzoriek **kalibračného setu**

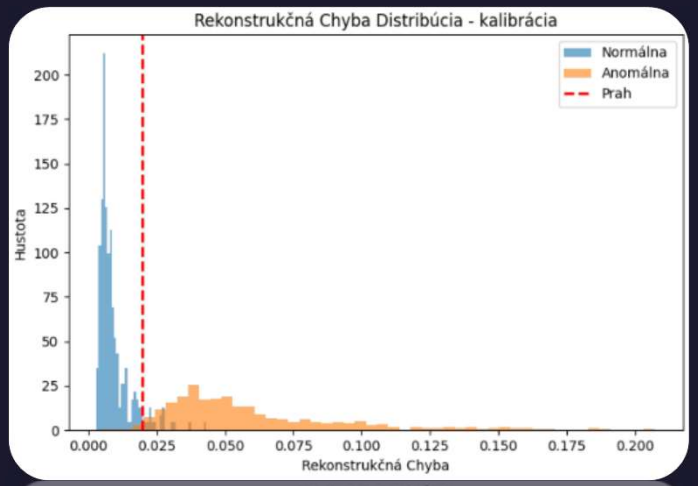
Identifikovať oblasť najmenšieho prekrytia ako počiatočný odhad prahu

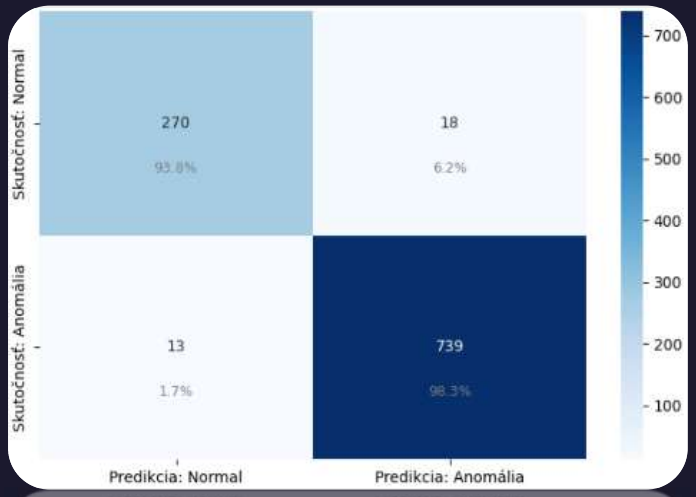
Iteratívne znižovať prah → sledovať Recall

Monitorovať Precision → udržať falošné alarmy v prijateľných medziach

Finálny prah overiť na **testovacej sade** — prevencia overfittingu na kalibračné dáta

Autoenkóder – zvolený prah 94%



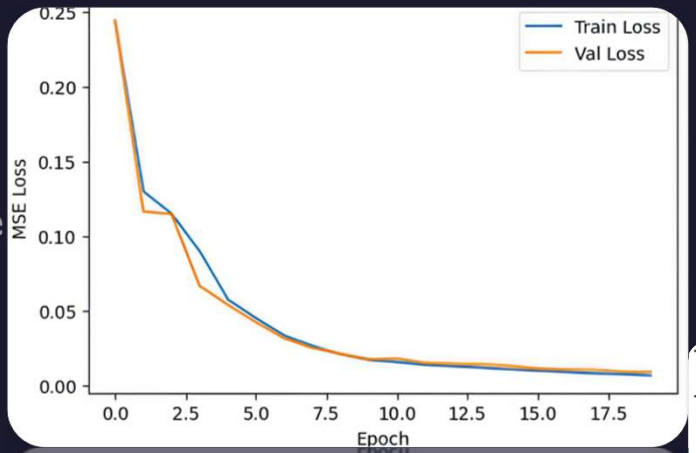



```
Ladenie percentilov:
Percentil → TP  TN  FP  FN  | FN-rate  FP-rate
90% → 744 259  29   8 | 0.011  0.101
91% → 743 262  26   9 | 0.012  0.090
92% → 740 265  23  12 | 0.016  0.080
93% → 739 267  21  13 | 0.017  0.073
94% → 739 270  18  13 | 0.017  0.062
95% → 732 273  15  20 | 0.027  0.052
96% → 724 276  12  28 | 0.037  0.042
97% → 707 279   9  45 | 0.060  0.031
98% → 689 282   6  63 | 0.084  0.021
99% → 656 285   3  96 | 0.128  0.010
```

Dosiahnuté výsledky

- FCDD = kompromis CNN (veľa anotácií) a autoenkódera (žiadne anotácie) — stačí **malý zlomok** defektných vzoriek
- CNN predstavuje strop supervised learningu — ale nasadenie v praxi je obtiažne, lebo defektné vzorky sú vzácne
- Autoenkóder prekvapivo konkurencieschopný napriek tomu že nevidel ani jeden defekt počas trénovania

Priebeh trénovania autoenkódera



Porovnanie % vplyvu prítomnosti defektných vzoriek na trénovanie autoenkódera

-	*1%*	*5%*
Citlivosť [Recall]	0.9845	0.9956
Presnosť [Precision]	0.9933	0.9956
f1 skóre	0.9889	0.9956
falošne pozitívne	3	2
falošné negatívne	7	2

TOP DOSIAHNUTÉ VÝSLEDKY

-	*CNN*	*FCDD*	*AE*
Priemerný čas trénovania [min.]	220	145	328
Počet parametrov siete [milióny]	21.04	19.60	22.30
Citlivosť [Recall]	0.9978	0.9956	0.9978
Presnosť [Precision]	1.0000	0.9956	0.9658
f1 skóre	0.9988	0.9956	0.9815

Ďakujem za pozornosť



